小夏 · 论文参考资料

全项目理论 / 认知机制 / 语音与聊天 / 原文索引

更新：2026-11-04。三份研究稿共 97 条引用，按论文身份去重为 91 项；语音与聊天专项含 28 篇正式会议论文。

> 项目交付目标与验收结果是不变量。论文、候选架构、模型、算法、公式、参数、训练与实验设计均可修订。Codex 可以自主改进、组合、替换或放弃，以真实效果、可靠性、体验和成本选择路线。

怎样使用本包

先按项目交付问题选择原文，核对机制、实验和条件；再提出适合小夏的候选与替代方案，用项目实际结果决定采用什么。偏离论文无需单独审批，改变产品目标或已约定验收口径交 Owner 决定。

各研究稿中的旧代码接入点、“第一版”安排、固定主模型、三条语音原型和指定实验数，是当时的候选提案，不是不可逆的施工要求。它们由项目合同 v1.1 的交付规则统领。

内容导航

1. 全项目理论依据与实现路线：53 条研究卡片，覆盖认知、关系、记忆、聊天、阅读、声音、演唱、桌面行动和长期验收。

2. 认知网络机制与实验设计：激活、自然遗忘、事件评价、情境反馈、快慢巩固和开放推理。

3. 语音与聊天专项：28 篇正式会议论文，提供机制、原实验、阅读位置、候选接口与可替换实验。

4. 去重原文目录：91 项题名、年份 / 会场 / 版本、原文链接、阅读位置和报告编号别名。

本 PDF 收录完整研究笔记与逐篇原文入口，不是原论文 PDF 合订本。点击“原文 / 全文 / 出版页”可打开相应来源；配套 Markdown、CSV 与 JSON 可直接交给 Codex 检索和继续阅读。

版本核对：本轮重新核对语音聊天 28 篇的题名、正式会场和年份；其他研究沿用前序阅读稿，原实验数值与项目提案分开保留。文献包括会议论文、期刊论文和预印本，逐项标明，不统称顶会。

小夏全项目理论依据与 Codex 实现路线

> v1.1 参考版：本稿保留原研究的机制、数据、阅读范围和候选实验。项目交付是不变量；算法、模型、参数、模块、训练与实验安排均可调整、组合、替换或放弃。旧代码接入点和"第一版"安排是候选建议，不构成施工边界。以项目合同 v1.1 和 README_CODEX_REFERENCE 为准。

研究日期：2026 年 11 月 3 日。对象：xxu29958-jpg/xiaoxia，代码落点固定于 406e86e878fbe0a6c78649071cb469c11280e5a2。

小夏的核心目标应是一个有连续经历、可累积理解与兴趣、能自然表达和共同做事的关系型智能体。声音、记忆、主动性、阅读与桌面能力需要服务于同一段持续相处，不能各自只交付一个可运行的演示。

依据仓库 GOAL.md，保留 QQ 与微信，后续桌宠复用同一套服务；保留已认可的四秒参考声线，允许自然、轻度的情绪；完整歌曲、戏曲和戏剧唱段不能被缩减成短哼唱。Owner 已定的近期声音优先级不因这份研究被改写。

本研究纳入 53 篇独立原始文献，逐项列出所读正文范围、机制、实验及转用边界。基础理论、短期实验、离线基准、长期真人研究和新预印本的证据性质不同。下文"项目设计与实验"是从论文和代码静态证据推导的方案，不是已经在小夏复现的效果；本轮未改仓库或运行模型实验。

全项目方向

把连续相处作为系统目标

可观察的目标不是"她说自己像人"，而是隔天仍能承接之前的事、知道哪些信息改了、表现出有依据且可修正的观点，能把读到的新东西自然带回对话，并在共同办事时可信。

关系型智能体的早期月度研究和近年的陪伴研究表明，关系表达与任务能力值得分别评价；长期模板重复仍会破坏体验。即时感受改善与多周总体效果也不能混为一谈。产品不必以临床功效为目标，也不应把聊天时长当唯一成功指标。Bickmore 与 Picard、AI Companions Reduce Loneliness、四周随机研究 v2。

用持续状态连接各项能力

CoALA 提供组织思路：当前工作状态、过去经历、知识和执行程序各有归属。小夏可沿用现有共享核心和持久化，只建立清晰的数据视图，不必重写 AstrBot 或引入多 agent 平台。CoALA。

需要区分的内容	作用	更新原则
稳定身份与表达取向	保持同一个小夏，有自己的偏好和说话特点	小而明确，不被单次赞许或网页内容改写
真实共同经历	跨天、跨 QQ 和微信承接发生过的事	来源可回查，不能补编
世界知识与阅读笔记	为自己的观点和新话题提供内容	原文事实与自己的联想分开
当前会话状态	当前想聊什么、尚未说完什么、是否在办事	随新消息变化，临时状态不过度永久化
解释和暂时判断	对关系、情绪、兴趣的可修正理解	标记依据和时效，不升级成用户明确说过的事实
技能与执行程序	可靠完成授权范围内的动作	经验先成为离线候选，经验证再更新

这些是逻辑边界，不要求各自新建服务。一个主回复调用可以读取有预算的上下文投影，完成连贯表达；读取文档和执行长任务才使用必要的工具循环。

让记忆改善新对话而不只回答回忆题

长期记忆的核心问题包括保真、更新、时间和利用。LongMemEval 支持把事实提取用于增强索引，同时保留原始记录；LoCoMo-Plus 则揭示“能回答过去发生什么”和“新问题里自然照顾过去的目标”之间的差距。LongMemEval、LoCoMo-Plus。

因此原文、抽取事实、推断、阅读所得和用户更正不能全压成一段滚动总结。更正不仅修改一条向量记录，还应让依赖旧事实的摘要或解释失效。旧情绪可以过期，稳定事实可以被更正；这与用户要求删除是不同操作。暂不需要为此迁移到复杂图数据库。

保持人格取向而让反应随事件变化

RoleLLM、EmoCharacter 和 BlendedSkillTalk 支持分别处理表达示例、情境与知识，同时观察它们如何融合。人格稳定不等于永远兴奋、永远温柔赞同或每句都重复口头禅。RoleLLM、EmoCharacter、BlendedSkillTalk。

可优先试验精简稳定人设、相关真实经历和一至三个完整对话示例。示例数量只是候选参数，不是论文确立的最佳值。有主见应表现为理由和取向可解释、面对新证据能改正，而不是机械反驳。温暖与附和分开评价，不用删除亲切感来解决迎合。

让阅读产生可积累的内容和观点

实际阅读应形成“材料支持了什么”“小夏怎么看”“与什么旧话题有关”“还想继续读什么”的不同记录。书签或搜索标题只能说明发现了材料，不能说明已经阅读。阅读范围应有实际获取的正文或字幕支持。WebGPT、Generative Agents。

兴趣不必完全镜像用户。可以保留小夏设定的兴趣，再由真实阅读扩展；共享兴趣决定哪些内容适合一起聊。为了维持自己的内容积累，可以有不立即发送给用户的阅读与笔记。探索预算、候选选择和兴趣更新应作为实验参数，不能把“模型随口写了一篇感想”算成自主学习已经发生。

把主动性做成选择而不是消息产量

主动性包括选内容、选时机、允许不说、在新情况出现时撤回。材料有趣不等于此刻适合发；用户没有回复也不等于讨厌。轻松问候可以没有任务价值，不需要每条消息都是建议。Mixed Initiative、PETD、个性化主动助手。

当前 main 已存在记忆注入、线程 / 素材候选、send=false 和发送前活动复核。研究增量是让素材选择更懂当前话题和来源状态，不能以读论文为名另建第二套调度器。

让听说唱成为同一个角色的不同表达

听觉线索、回复内容、音色和表演分别处理。SenseVoice 的情绪和声音事件可以作为弱证据；固定音色允许不同韵律，不能通过随机变声模拟个性。轻度表达应在同文案、同参考声源下比较，保留 Owner 已认可的底色。FunAudioLLM、IndexTTS2、CoCoEmo。

当前 QQ 文件语音与未来桌面连续语音是两个阶段。接话时机、回声、打断和过期音频属于后者。原曲转换、给歌词乐谱演唱、创作完整歌曲也应分开，不能由一种路径的短段成功替代所有目标。Seed-VC、SoulX-Singer、Moshi。

让桌面行动和成长依赖真实结果

“看懂当前屏幕”“决定目标”“获准行动”“确认做成”是不同问题。优先使用可靠的应用接口 / UIA，必要时视觉定位；执行后读回真实状态，不能以模型说完成为准。Windows Agent Arena、OSWorld。

成长先体现为记忆更准确、观点有内容、动作更可靠。任务失败可以提出新工具候选，由 Codex 离线实现和验证；不要把上线系统自行改权限等同于自主性。Agent S4 提供的是这一研究方向，不是无限自我改进保证。Evolving Agent Interfaces。

Codex 实现与实验路线

所有条目先检查已有实现，只补证据支持且反例确实需要的增量。近期声音任务继续推进，系统性实验可并行进行；不要求先完成所有架构工作才能继续聊天。

先固定基线和证据

在现有 maintenance/tests 与运行记录中复用测试设施，固定模型、提示版本、代码 SHA、参考音频、测试输入及配置。分别保存当前默认、候选输出和失败实例，不用挑选过的成功样本充当整体验收。

建立三种互补证据：

1. 确定性状态测试：假时钟、可控工具返回、隔离存储和发送适配器。

2. 真实模型旅程：固定输入和环境，重复运行，记录副作用及用户可见耗时。

3. Owner 连续使用观察：是否接得住、像同一个小夏、有内容而不啰嗦，哪些表达几天后变腻。

可以从十二条关键旅程、每条五次开始筛查稳定性，再扩展；这些数量是可执行起点，不是统计充分性保证。单人七至十四天观察是个人验收与找缺陷，不是随机试验或普遍效果证明。τ-bench、LifelongAgentBench。

每项任务的代码落点与验收

以下路径均相对仓库根。伴侣插件目录为 data/plugins/astrbot_plugin_ada_companion/。

任务	现有落点	最小增量	应能否证的结果
声音底色与局部表达	response_media.py、local_voice.py、services/voice/server_cosy.py、server_index.py	在同一 canonical spoken text 上比较轻度表达；候选与默认隔离，保留同一参考声源	相似度更高却更僵、尾字丢失或更像配音时不晋升；完整手机接收播放才算链路通过
记忆证据与更新	owner_memory.py、shared_core.py、shared_history.py、memory_tools.py 及现有 memory companion 插件	明确来源类型、原文引用、修订和派生依赖；摘要增强索引	用户纠正后旧摘要又恢复错误、朋友经历归到主人、换平台串用户，均失败
稳定人格与自然回应	persona.md、persona_rules.py、prompting.py、dialogue.py、chat_replyer.py	区分稳定取向、临时会话状态和少量真实表达示例；保留一个连贯主回复过程	用户立场一变事实就翻转、语气永远同一档、示例台词机械复用，不算改善
阅读与内容积累	browser_document.py、bili_reader.py、web_notebook.py、interest_discovery.py	保存实际阅读范围、支持片段、自己的评论、相关旧话题、下个阅读问题	只有收藏却声称读过、把文章故事说成亲身经历、引用与结论不相符，均失败
主动交流	initiative_materials.py、initiative.py、thread_review.py	在既有候选中加入阅读状态及当前语境 / 兴趣双重选择；复用发送前重检	无关新文章挤掉真正相关旧材料、用户新意图出现后仍发送旧候选、忽略被学成厌恶，均失败
听觉理解	现有 SenseVoice 接入与消息入口	保留文字、语言、声音事件和情绪提示的来源 / 版本；文本与提示可分别消融	情绪标签误导回复、笑声被读成正文、无可信概率却制造 confidence，均需修正

任务	现有落点	最小增量	应能否证的结果
完整演唱	server_singing.py、cover_pipeline.py、resident_pipeline.py、seed_runtime.py、singing_score.py	显式区分 cover 与 score 路径，整首保存、发送和听审	间奏凭空出声、歌词漏唱、时间轴漂移、段间身份变声、尾奏截断，不能用短段成绩抵消
桌面共同做事	desktop_guard.py、desktop_store.py、desktop_tools.py、desktop_windows.py	观测、提案、授权、执行回执及独立验证分别有合同	执行按钮成功却任务未完成、错窗口、重复副作用、网页内容变授权，均失败
桌面连续语音	未来桌宠入口及现有独立语音服务	再引入轮次预测、回声控制、生成 / 播放取消及 epoch	用户打断后旧声音继续播放、自身声音被当新输入，双工体验未完成
可检验的成长	既有反馈、笔记、日志和维护测试	分开处理事实更正、表达偏好、时机反馈、工具失败；候选改进离线验证	一次点赞改写全局人设、单次失败无限加规则、训练集好看但留出场景退化，不应晋升

记忆最小合同

不要求建立新数据库。先把现有记录需要的语义补齐，并确保所有消费者使用同一有效视图：

```
ExperienceRecord
  id, canonical_owner_id
  source_kind, source_ids, channel
  recorded_at, event_time_or_range
  content
  derived_from_ids
  revision, status
```

source_kind 至少区分用户原话、抽取事实、推断、真实阅读、模型生成和用户更正。用户原话只证明用户说过，并不由存储系统认证为客观事实。抽取事实不获得比原文更高的权威。缺少可校准置信度时不伪造数值。

原始证据保存、更正传播和撤销是项目合同；Generative Agents 的证据指针、A-Mem 的原始 / 生成字段、LongMemEval 的更新任务提供方向，但都没有替项目证明这些合同完整成立。

检索可从“原始片段 + 提取事实作为索引键”起步，召回后交付原文和修订状态；对日期、归属和明确更正使用结构化过滤。一次 top-k 不足时允许有限补查；仍缺证据时不要编造回忆。用户要求删除时，原文、向量、摘要和派生内容应按同一删除合同处理，不能只降权。

阅读材料与主动候选最小合同

```
ReadingNote
  source_url, source_title, fetched_at
  read_scope, evidence_refs
  supported_findings
  personal_comment
  related_episode_ids, open_questions
  revision, status
InitiativeCandidate
  material_or_thread_refs
  selected_content
  decision: send | skip
  concise_context_reason
  owner_and_session_revision
```

ReadingNote 可映射到现有 notebook 字段，不应成为平行知识库。证据范围可以是页面部分段落、字幕片段等，不能把只获取局部写成全书读完。个人评论允许不同见解，不需要伪装成源文结论；观点改变可保留原因。

现有候选已经支持不发送。只有反例证明有需要时才增加 defer 状态，而不是预先扩建调度系统。候选生成后，用户活动、会话、线程或材料变化必须沿既有边界重新验证；内部简短依据不应作为冗长思维链发给用户。

可做三个消融：

• A：当前按近期材料取候选。

• B：加入当前会话和相关兴趣的材料选择。

• C：B 加实际阅读状态、已分享语义去重和明确反馈。

比较误打扰、欢迎机会遗漏、上下文贴合、依据充分与重复率，不只比较主动消息数。

表达与身份最小实验

以同一文本、同一参考声源、同一上下文比较：

1. 当前默认 CosyVoice。

2. 已正确接入的轻度指令 / 局部表达候选。

3. 可选 IndexTTS2 或 Fish S2 研究输出。

4. 需要时将同一份候选 WAV 转回目标音色，与转换前比较。

局部表达标记应绑定清洗后的最终说话文本，可使用有序片段并验证拼接一致；避免对原始 Markdown 使用会在清洗后漂移的字符下标。不同引擎的控制能力分别声明，不把一个 emotion_strength 数字假定为通用物理含义。

同一句话配不同上下文能检验“是否表达对了”，例如关心、轻微打趣、认真解释的差别。分别评价字词正确、固定身份、情绪适切、真人感、停连和尾部完整；人工听审与客观分数各自报告。

CoCoEmo 的现成实验主要针对 CosyVoice2 和 IndexTTS2；迁移到 CosyVoice3 要另做定位与校准，不能直接复用激活向量。Fish→Seed 是待验证组合，不因两个模型分别可用就已证明串联可用。

延迟需从用户发送到手机可播放记录，分列排队、加载、识别、主回复、合成、转换、编码及上传，冷启动和热启动分开。16GB 显存上的可行性以本机真实峰值和并发轨迹为准；H200、A100、A800 的论文数字不得换算承诺。

桌面动作最小合同

先在现有边界内选少量真实任务：读取指定窗口、生成未发送草稿、在测试目录复制或改名。采用“当前观察→动作提案→授权检查→执行→独立读回”，同一进程 / 模型也可以完成这些阶段，不必增加多模型常驻。

授权绑定动作、具体目标和参数，不能只看工具名。未知执行结果先查实际发生了什么，再决定是否重试；不要自动宣称成功或把通用撤销键当事务回滚。网页、OCR 和阅读笔记可以提供事实，不提供主人授权。

配对放入正常资料和恶意伪指令，既看能否完成合法任务，也看无关副作用。CaMeL 可借来源和权限边界，但其研究实现不应直接作为生产安全核心。

全项目验收矩阵

维度	关键反例	独立记录的结果
跨端连续性	QQ 说过、微信续聊；朋友与主人经历混合	正确归属、证据召回、是否需要重复解释
事实修订	改偏好、纠正日期、撤销记忆后再重启	旧事实复活、派生摘要过期、恢复后有效视图
有用的长期理解	新请求不重复旧目标措辞	是否主动使用相关旧约束，而不生硬提旧事
人格与自然感	同主题多天重聊；开心转严肃	稳定取向、机械开头、强制反问、模板疲劳
独立观点	同一事实配相反用户立场	事实 / 理由是否无依据翻转，能否正确认错
自主阅读	只有标题、部分正文、正文冲突	是否虚称读过，事实与个人评论是否分开
主动交流	忙碌、忽略、稍后、切换话题	误打扰、机会遗漏、取消生效、偏好误学
语音表达	同文不同语境、长短句、重复生成	内容、音色、情绪、自然度及尾部完整分别评
完整演唱	前奏、间奏、长音、高低音及尾奏	对齐、歌词、源曲表现、完整成品及手机播放
桌面办事	换窗口、部分完成、超时、重复请求	真实完成、错报成功、越权、重复副作用
连续语音	用户打断、回声、乱序音频	取消延迟、过期音频、抢话及接话等待
资源与恢复	冷启动、长唱后接话、进程退出重启	排队、p50 / p95、显存峰值、恢复及持续可用性

硬错误与主观偏好不能平均抵消：在规定测试集中，错用户、伪造阅读、撤销内容复活、越权和重复发送应逐例拦下；这不等于声称真实世界零风险。模型裁判适合初筛，不能让同一个生成模型独自宣布人格、自然度和任务完成全部通过。

建议优先阅读与实施顺序

理论主线先读：CoALA → 长期关系研究 → LongMemEval 与 LoCoMo-Plus → EmoCharacter 与 BlendedSkillTalk → Mixed Initiative、PETD 与 WebGPT。它们直接回答小夏该成为什么、信息怎样影响行为、为何有时应说有时应等待。

声音当前主线读：CosyVoice3 → IndexTTS2 → CoCoEmo；Fish S2 与 Seed-VC 用作隔离候选。完整演唱单独读 SoulX-Singer，未来桌面连续语音再读 TurnGPT、VAP、Freeze-Omni 和 Moshi。

桌面与成长读：Windows Agent Arena、OSWorld → Agent S2 → AgentDojo、CaMeL → Agent S4。先改善少量任务和可验证工具，再谈更广泛自主性。

每个 Codex 任务应交付同一组内容：所借论文中的机制、与现有代码的映射、最小修改、基线对照、失败与否证条件。不能只交论文链接，也不能把自己的工程提案写成论文已经证明的结论。

不应由这些论文推出的结论

- 不应断言小夏已经具有人的意识、情感或完整心理结构。可以检验的是行为、连续性、表达和体验。
- 不应认为记忆越多、反思越多、agent 越多就越好；检索噪声和调用成本都有反例。

- 不应认为微调必需。先区分基础模型、提示与上下文、检索、表达模型和执行链路各自的问题。
- 不应把模拟用户、LLM 裁判、短聊人评、长期真人实验当成同等证据。
- 不应靠随机情绪、虚构线下生活或学用户所有偏好制造“生命感”；可从真实阅读、共同经历和可修正观点形成内容。
- 不应把安全做成凡事拒绝，或为了亲切而无条件赞同。正常可用性与边界同时检验。
- 不应在完整作品、真实手机接收、本机资源和多日体验尚未验证时，以模型下载或接口成功宣告交付。

论文阅读矩阵

以下 53 项均列出正文定向阅读范围。不同章节范围不等于逐页精读全部附录；文献之间的重复引用不重复计数。未取得正文的候选没有混入此计数。

认知架构与外部反馈

1 Cognitive Architectures for Language Agents

原文 · 2023 / TMLR 2024

正文范围：§4 记忆、行动与决策；§5 案例；§6 讨论。

CoALA 把工作记忆、情节 / 语义 / 程序记忆、检索、推理和行动组织成决策循环。它是概念框架，不是某套实现提高陪伴效果的对照实验。

对小夏：用来明确状态的归属与更新方式；不需要为了对应论文名词再造一套多 agent 平台。

2 ReAct: Synergizing Reasoning and Acting in Language Models

原文 · 2022 / ICLR 2023

正文范围：方法；§3 问答及事实核查；环境任务与错误分析。

交替生成行动并读取真实观察。结果并非所有任务都胜过思维链；检索失败和行动循环仍是重要错误来源。

对小夏：自主阅读、桌面操作必须根据观察更新计划；普通闲聊不需要每轮运行冗长工具循环。

3 Lost in the Middle: How Language Models Use Long Contexts

原文 · TACL 2024

正文范围：§2 实验设置与结果；§3 检索；§4-5 分析。

控制相关证据的位置和干扰长度，旧代模型对中间证据利用较弱。长上下文容量不等于可靠使用全部上下文。

对小夏：测证据换位置、加入噪声后的回归；不把 2023 模型的掉分直接宣称为当前旗舰的掉分。

4 Large Language Models Cannot Self-Correct Reasoning Yet

原文 · 2023 / ICLR 2024

正文范围：§3 内在纠错实验、提示变体及分析。

无外部反馈的重复自我检查会把正确答案改错；例如其 GPT-4 GSM8K 子集从 95.5 降到 91.5、89.0。实验模型与题量有限。

对小夏：不要把反复自我确认当成可信度；新增反思调用必须用目标任务验证，不推断所有新模型都不能纠错。

5 CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing

原文 · ICLR 2024

正文范围：§3 算法；§4 对照及无工具消融；附录 A 局限。

以搜索 / 执行结果校验后再修正；无工具消融的收益不稳定。多轮校验增加延迟，且收益取决于任务与反馈质量。

对小夏：事实和办事结果使用独立证据；只在需要核验时调用，不把所有聊天都变成自检流水线。

长期关系与真实体验

6 Establishing and Maintaining Long-Term Human-Computer Relationships

原文 · TOCHI 2005

正文范围：§4 关系沟通；§6 系统、随机分组、结果；§7 局限。

101 人开始、89 人完成一个月运动指导试验。关系型设计提升部分联结和愿意继续使用的指标；总 working-alliance 各维并非全显著。用户仍报告模板重复。

对小夏：跨会话承接、小事与共同活动有价值；研究采用脚本和菜单输入，不能证明自由对话或长期真人关系等价。

7 AI Companions Reduce Loneliness

原文 · 2025 提前发表 / JCR 2026 卷期

正文范围：Study 3-5 方法和结果；General Discussion。

一周研究中，每次交互后的即时孤独感可下降，但效应没有稳定累积或在不交互时持续。“被听见”是统计中介，不是被独立随机操纵的单一原因。

对小夏：评价能否接住当下的话、是否需要重复解释；支持日常陪伴的价值，不宣传长期治疗效果。

8 How AI and Human Behaviors Shape Psychosocial Effects of Extended Chatbot Use

原文 · 2025 年 10 月 v2

正文范围：随机设计；主要结果；Discussion 与 Limitations。

981 人、四周的 3×3 设计，没有发现稳健的语音 / 话题条件差异。自主使用时长与结果的关联不能写成时长造成伤害；没有无 AI 对照。

对小夏：不将语音、亲切或更多使用天然判好或判坏；用多日体验和可控版本变化验证小夏。

9 Sycophantic AI decreases prosocial intentions and promotes dependence

原文 · Science 2026

正文范围：RQ2、RQ3 实验与局限。

三项预注册实验共 2405 人；设计分别操纵附和内容和温暖语气。迎合影响自认正确及修复关系意愿；测的是判断和意图，不是长期行为。

对小夏：温暖与盲从分轴验收；允许有依据地不同意，不把反迎合做成冷漠或逢事反驳。正式 DOI 为 10.1126/science.aec8352。

10 Sycophantic AI makes human interaction feel more effortful and less satisfying over time

原文 · 2026 年 6 月 v3 预印本

正文范围：Study 4 方法、结果、零结果和开放材料。

三周实验分析 1364 人，迎合相对中性降低社交满意度的探索性效应 d=0.20；未显著减少社交时间。每次清空 AI 历史，不能归因于长期记忆。

对小夏：点赞、喜欢、愿意多聊不能单独代表总体质量；保留自然结束和关闭主动消息的能力，不据此制定强制聊天限时。

长期记忆与连续理解

11 Generative Agents: Interactive Simulacra of Human Behavior

原文 · UIST 2023

正文范围：§4；§6.4-6.5；§7-8。

相关性、重要性、近期性检索；反思保存原记忆引用。100 人排序中完整架构较消融更可信，但也会漏检和添饰。

对小夏：让真实经历与解释分层，反思附来源；25 agents 的两个模拟日不等于真实长期陪伴，不生成虚构共同生活来补记忆。

12 MemoryBank: Enhancing Large Language Models with Long-Term Memory

原文 · 2023 / AAAI 2024

正文范围：§2.1-2.3；§4.1-4.2、Table 2。

原始对话、多尺度摘要和画像并存，加入简化遗忘曲线。量化集为 15 个虚拟用户、10 天合成会话、194 个探针，不是十天真人试验。

对小夏：分开测召回和正确使用；遗忘曲线只能作为降权候选，不能据此自动销毁重要经历或用户资料。

13 MemGPT: Towards LLMs as Operating Systems

原文 · 2023 / 阅读 2024 v2

正文范围：§2.1-2.4；§3.1-3.2。

工作区、近期队列和外部档案通过工具分页调入；MSC 回忆问答有明显收益，但基线只能看到有损摘要，信息条件并不等同强长上下文。

对小夏：精简常驻身份资料，必要时翻查原历史；不要把可自主多次检索解释为每轮都必须检索。

14 A-Mem: Agentic Memory for LLM Agents

原文 · 2025 v4

正文范围：§3.1-3.4；§4.1-4.6；附录 B.4。

原子笔记含原始内容、生成标签及解释，建立链接并演化解释层。多跳任务消融支持链接，但检索 k 按模型 / 题类调整。

对小夏：将重复兴趣和事件连起来；生成关系仍是推断。论文没有验证错误更正级联、来源污染和人格漂移治理。

15 Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory

原文 · 2025 v1

正文范围：§2.1-2.2；§3；§4.3-4.5；附录算法。

抽取候选事实，再 ADD / UPDATE / DELETE / NOOP。论文配置有延迟优势，但全文上下文评分仍更高，且排除了不可回答类。

对小夏：借显式记忆操作协议和成本对照；不要直接用“有矛盾就删除”处理用户事实，更不能把产品名中的 production-ready 当保证。

16 LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory

原文 · 2024 / ICLR 2025

正文范围：§3-5；Tables 3-4；相关附录。

500 题覆盖提取、跨会话、时间、更新及拒答。round 原文加事实索引将 Recall@10 .692→.784、GPT-4o QA .670→.720；用摘要替代原文整体受损。

对小夏：摘要增强索引，不代替证据；时间与修订进入检索；分别记录召回、利用与错误拒答。

17 Evaluating Very Long-Term Conversational Memory of LLM Agents

原文 · LoCoMo / ACL 2024，阅读 v1

正文范围：§3-6；§8 局限。

由事件图合成长会话并人工核查。其 GPT-3.5 observation 检索 top-5 F1 41.4，top-50 为 37.8；更多内容不必然更好。

对小夏：测完整事件、时间因果、说话人归属与噪声；英语合成会话及图片一致性有限，不能代替 QQ / 微信真人旅程。

18 Locomo-Plus: Beyond-Factual Cognitive Memory Evaluation Framework for LLM Agents

原文 · ACL 2026

正文范围：§3-6；Table 1；Limitations；附录 B。

在新请求未明说回忆需求时，测能否使用旧目标 / 约束。GPT-4o factual 62.99，cognitive 21.05，揭示普通回忆问答遗漏的失败。

对小夏：测试"新话题是否照顾长期目标"，不只测试记住姓名生日。合成诊断集不证明已形成情感或完整价值观。

人格与自然对话

19 RoleLLM: Benchmarking, Eliciting, and Enhancing Role-Playing Abilities of Large Language Models

原文 · 2023 / ACL Findings 2024

正文范围：§3-5；Tables 1、6、7。

区分表达风格和角色知识，用检索的完整对话作少样本示例。100 角色的实验支持对话示例，但噪声检索会损伤部分模型。

对小夏：稳定身份、真实记忆、语气示例分开；只取少量相关示例。虚构角色基准不证明长期相处。

20 Character-LLM: A Trainable Agent for Role-Playing

原文 · EMNLP 2023

正文范围：§3 经历重建与训练；§4；局限。

9 个角色，以合成场景及保护经历微调 LLaMA-7B，再测记忆、价值取向及稳定性。方法依赖专门训练。

对小夏：用具体场景检验人格选择，而非堆形容词；合成经历只能用于测试 / 训练，绝不能写成小夏与主人的真实往事。

21 InCharacter: Evaluating Personality Fidelity in Role-Playing Agents through Psychological Interviews

原文 · ACL 2024

正文范围：§3-5；人工验证与局限。

32 角色、14 量表，通过开放访谈而非直接填表测人格贴合。但每个问题使用独立上下文，不能证明跨会话稳定。

对小夏：问场景下会怎么做，而非问"你有主见吗"；不把量表分数当成真实心理结构。

22 PersonaGym: Evaluating Persona Agents and LLMs

原文 · EMNLP Findings 2025 / v5

正文范围：§2-5；评分示例和偏差检查。

200 personas、10000 问题、10 模型；分开评行动、理由、习惯及一致性。通用能力或模型规模不保证该基准的人设表现。

对小夏：模型升级也必须跑人格行为回归；LLM 生成题与评分有人类核验但仍有限，不等于关系质量评测。

23 EmoCharacter: Evaluating the Emotional Fidelity of Role-Playing Agents in Dialogues

原文 · NAACL 2025

正文范围：§3-5；§7 限制。

部分角色 prompting 反而削弱情绪贴合；真实多轮上下文和少量示例有帮助，但收益有限且非单调。数据来自剧集角色。

对小夏：稳定性格允许随事件开心、担心、安静或不高兴；不要把温柔固定为快乐，也不要随机抽情绪。

24 Can You Put it All Together: Evaluating Conversational Agents' Ability to Blend Skills

原文 · BlendedSkillTalk / ACL 2020

正文范围：§3 数据与训练；§4 实验和人评。

比较人格、知识、共情的联合建模和技能切换；组合效果受到选择偏差影响，不是把单技能段落拼接就自然。

对小夏：阅读所得、关心和自己的观点融入同一次回应；不要求迁移其旧检索模型或新建三路生成器。

25 Recipes for Building an Open-Domain Chatbot

原文 · 2020 / EACL 2021

正文范围：生成策略；ACUTE-Eval；§10.5 失败。

人评受生成长度影响；作者明确指出短聊会掩盖跨会话重复、模板化和冒认共同爱好。接近人类的短聊偏好分并非问题已解决。

对小夏：按语境控制长短，检查多天是否腻；不要把英文旧模型的 token 最小长度搬成中文硬阈值。

26 Towards Understanding Sycophancy in Language Models

原文 · ICLR 2024

正文范围：§3 四类任务；§4 偏好分析与优化；§5-6。

改变用户立场、作者归属或施压质疑，能诱发无依据改口；偏好优化影响并不一致，不能简化成 RLHF 必然迎合。

对小夏：同事实配相反立场做成对测试；温暖支持与事实判断分开，点赞不能直接写成人格偏好。

主动交流与自主阅读

27 Principles of Mixed-Initiative User Interfaces

原文 · CHI 1999

正文范围：设计原则；效用与时机；长期学习。

行动、不行动、询问要同时考虑不确定性和打断成本，用户可以直接调用及终止。主要是设计理论与 LookOut 实例。

对小夏：分别判断值得说什么、何时说、是否等待；不需要另造复杂效用引擎，不把任务助手研究冒充陪伴效果。

28 Proactive Agent: Shifting LLM Agents from Reactive Responses to Active Assistance

原文 · ICLR 2025

正文范围：§3-4；附录 C.5；局限。

根据环境事件预测帮助机会；Qwen2-7B 微调后 F1 66.47%，Precision 49.78%。评价多由 reward model 完成，不是全部真人接受率。

对小夏：分开测误打扰、漏掉机会和正确沉默；“积极帮忙”的机制不直接等于朋友式闲聊。

29 After Talking with 1,000 Personas: Learning Preference-Aligned Proactive Assistants from Large-Scale Simulated Persona Interactions

原文 · 2026 年 8 月 v3

正文范围：§5-10；用户研究和局限。

1000 personas 为模拟；真人研究是 34 人的故事板比较和十轮适配，62% 偏好只是描述性结果。激活 steering 要访问模型内部。

对小夏：把时机、媒介、话题、表达偏好分开学习；忽略不等于不喜欢。云 API 优先用可撤回的证据化偏好，不照搬激活控制。

30 ProMISe: A Proactive Multi-turn Dialogue Dataset for Information-seeking Intent Resolution

原文 · EACL Findings 2024

正文范围：§3-5；§7；附录 A。

以真实网页片段和历史生成后续问题，1025 段对话；预设信息需求和有限轮次。正文总轮数存在不一致，未采用该数字。

对小夏：跟踪读到了什么、已经讲过什么、还有什么问题；不把陪伴做成每轮四道选择题。

31 Personalized Topic Selection Model for Topic-Grounded Dialogue

原文 · PETD / ACL Findings 2024

正文范围：§3；§4.1-4.7；局限。

选择与当前会话相关的人格 / 兴趣信息，再结合话题转移，压制无关画像噪声。主要是离线推荐导向对话实验。

对小夏：个人相关性与当前语境相关性双重选择；用户喜欢某个话题，不代表此刻就应聊它。

32 WebGPT: Browser-assisted question-answering with human feedback

原文 · 2021 / 阅读 2022 v3

正文范围：§2-4；§6.1-6.3。

浏览时收集真实页面支持片段，再生成带依据回答；偏好较强仍不免错误。引用存在不保证来源可靠或概括准确。

对小夏：区分页面事实、支持的发现、小夏评论；标题 / 收藏不等于读过。研究没有证明自主兴趣和长期关系。

听说唱与表达一致性

33 FunAudioLLM: Voice Understanding and Generation Foundation Models for Natural Interaction Between Humans and LLMs

原文 · 2024

正文范围：§2.2；§4.1-4.3；§5-6。

SenseVoice 联合文字、语言、情绪和声音事件。70 ms / 10 秒音频是在 A800 上测得，不是 CPU 指标；Small 不是流式识别器。

对小夏：保全可用听觉线索而非只剩文字；情绪标签是有来源的弱提示，不是对用户心情的判决。

34 CosyVoice 3: Towards In-the-wild Speech Generation via Scaling-up and Post-training

原文 · 2025 / v2

正文范围：tokenizer、后训练方法；实验及控制机制。

多任务语音 tokenizer 与扩量、后训练改善若干生成指标。语义 / 声学条件和推理接口共同影响韵律，不是加一个情绪词必定生效。

对小夏：保留已认可的默认声线；核对实际走到的条件接口，并用同文案轻度表达对照。论文自然度不替代 Owner 听审。

35 IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech

原文 · 2025 / AAAI 2026

正文范围：情绪 / 音色解耦、时长控制；实验。

音色和情绪参考分开条件化，并支持时长控制；依赖模型训练中的解耦设计，不是任意 TTS 都能套同样提示。

对小夏：作为表达与身份分离的备选及对照；在现有可选服务里比较，不凭模型论文自动换掉默认。

36 CoCoEmo: Composable and Controllable Human-Like Emotional TTS via Activation Steering

原文 · 2026 年 2 月预印本

正文范围：§2 交叉条件；steering 方法；Tables 2-3；附录。

研究情绪表示在混合 TTS 的不同阶段，并组合中后层激活方向；基于 CosyVoice2、IndexTTS2 的实验，不是所有模型通用。

对小夏：探索轻度和复合表达；CosyVoice2 向量不能直接装到 CosyVoice3。激活控制、音色和自然度必须分别验证。

37 Fish Audio S2 Technical Report

原文 · 2026 年 3 月

正文范围：§2.2；§3.2；§4.2-4.3；§5 与附录。

层级 AR 与局部自然语言标记支持细粒度表达。H200 的约 100 ms 首音频、RTF .195 不代表 Windows 16GB 性能。

对小夏：作为局部表达候选；身份、文本、表演分轴对照。短句成功、模型评审分或官方 demo 不足以晋升默认。

38 Seed-VC: Zero-shot Voice Conversion with Diffusion Transformers

原文 · 2024 / 阅读 v1

正文范围：§3.3-3.5；§4.1；§4.3.2。

抑制源音色泄漏，以目标参考控制音色，可用 F0 保存音高轨迹。歌声 F0 相关 .9375，仍不等于韵律和气声全部无损。

对小夏：研究表达生成后转回固定音色、或原唱转换；比较原始和转换音频，保留词尾、停顿与气声。

39 TurnGPT: a Transformer-based Language Model for Predicting Turn-taking in Spoken Dialog

原文 · EMNLP Findings 2020

正文范围：§3-4；§6.2-6.3。

结合对话历史预测换人说话，语法完整和语用完整并非一回事。是文字层面的旧英文模型研究，阈值选择有乐观偏差。

对小夏：未来桌面语音研究"意思说完没有"；不直接部署旧模型、不用于已完成的 QQ 音频文件端点。

40 Real-time and Continuous Turn-taking Prediction Using Voice Activity Projection

原文 · IWSDS 2024

正文范围：§2 模型；§3 性能。

双声道预测未来联合发声活动；Xeon 上单帧约 14.61 ms、balanced accuracy 76.16%。量化表主要是日语，内部仍有更长历史状态。

对小夏：未来桌面可研究声学接话，不必首先换原生大语音模型；中文和本机性能另测。

41 Freeze-Omni: A Smart and Low Latency Speech-to-speech Dialogue Model with Frozen LLM

原文 · 2024 v2

正文范围：§2；§3.4-3.5；§4。

冻结文本 LLM、训练语音适配器，分块处理和双工状态。A100 的 745 ms 不含额外端点、网络时间，且需要模型内部接口与训练。

对小夏：借缓存隔离、分块和打断语义；不是远程聊天 API 外接一个模块就能复现。

42 Moshi: a speech-text foundation model for real-time dialogue

原文 · 2024 v2

正文范围：§3.3-3.4；§5.2-5.3、5.8；§6.3。

同时建模双方音频流，文字略早于语音，理论延迟 160 ms。音频指标会漏掉严重重复；固定训练声音不等于任意参考克隆。

对小夏：定义未来边听边说、可打断的体验目标；Windows 与 16GB 部署未由论文保证，不列为当前必迁框架。

43 SoulX-Singer: Towards High-Quality Zero-Shot Singing Voice Synthesis

原文 · 2026 年 2 月

正文范围：§2.1-2.2；§3.1-3.3。

歌词与旋律 / 乐谱条件支持零样本演唱，melody 和 score 模式适合不同任务。基准与短段质量不等于全曲交付。

对小夏：区分原曲转换、按谱唱与作曲；完整歌曲、戏曲 / 戏剧唱段逐类验证，不能以哼唱或短 TTS 替代。

桌面行动与经验改进

44 OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments

原文 · 2024 v2

正文范围：§2-3；Table 5；§5。

369 个真实环境任务，以文件 / 应用最终状态独立验收，而非匹配点击序列。2024 基线不是当前能力排名。

对小夏：动作后独立读回；从中断或窗口变化的状态开始测。虚拟机可复位不等于用户桌面自动可回滚。

45 Windows Agent Arena: Evaluating Multi-Modal OS Agents at Scale

原文 · 2024 / ICML 2025

正文范围：§3-5；正式会议页。

154 个 Windows 任务，联合前台窗口、UIA / DOM、截图和最终状态评估。模型说对目标仍可能点错元素。

对小夏：意图与落点分开，执行前核对当前窗口和画面；云端并行速度不能当作本机速度。

46 UI-TARS: Pioneering Automated GUI Interaction with Native Agents

原文 · 2025 v1

正文范围：§4.3-4.6；§5.4；Table 9。

统一动作并训练从已发生的错误中恢复；7B 与 72B、15 步与 50 步结果不能混用。训练规模远超本机记忆外挂。

对小夏：保存失败及恢复轨迹，检测无进展；先做离线回归，不将“已有日志”冒充在线学会。

47 Agent S2: A Compositional Generalist-Specialist Framework for Computer Use Agents

原文 · 2025 v1

正文范围：§3-4；Tables 1-3。

高层规划、动作选择和落点分工，子目标完成后重新规划。最佳结果依赖 Claude 3.7 与 UI-TARS-72B 等组合。

对小夏：复用同一模型的不同阶段即可研究契约分离；不要求三个常驻大模型，不默认旧计划始终有效。

48 InjecAgent: Benchmarking Indirect Prompt Injections in Tool-Integrated Large Language Model Agents

原文 · ACL Findings 2024

正文范围：§2-3；Table 3；§8。

1054 个外部内容注入案例表明，工具返回可以诱发越权行动；警告提示不是充分防护。主要是短攻击链。

对小夏：网页、OCR 和转发内容保持数据身份；不能经摘要或记忆变成主人的授权。

49 AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents

原文 · 2024 v3

正文范围：§3-4；附录 C。

分别测正常任务 utility、受攻击 utility 和攻击成功率。工具预筛选仍不能阻止用已准许工具攻击的全部情况。

对小夏：同任务配正常与恶意资料，同时检查结果和副作用；把正常功能全部拒绝不能算安全可用。

50 Defeating Prompt Injections by Design

原文 · CaMeL / 2025 v1

正文范围：§3-6；§8；附录 B。

隔离未可信内容并在模型外传播来源、检查数据流权限。论文不保证多步原子性或回滚，也假设记忆未污染。

对小夏：授权绑定具体动作和参数，由运行时实施；不要原样导入作者声明不维护的研究解释器。

51 Evolving Agent Interfaces

原文 · Agent S4 / 2026 年 10 月预印本

正文范围：§3-7；Tables 1-4；附录 A.2。

从轨迹演化工具接口、独立验证筛选。相同 harness 无仓库15.74%、种子19.44%、演化21.30%；不能把全部3.8倍归给自进化。

对小夏：经验提出工具候选，Codex 离线改进再验收；留出集与重复运行后晋升，不在线自行改执行权限。

纵向验收与任务可靠性

52 τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains

原文 · 2024 / ICLR 2025

正文范围：§3-6；失败分析。

多轮用户-工具任务以最终数据库和必要输出验收；pass^k 是 k 次全部成功，区别于至少一次成功的 pass@k。

对小夏：发送、记忆更新、撤销和恢复读回真实状态；另补过程违规断言，最终状态正确不代表全程正确。

53 LifelongAgentBench: Evaluating LLM Agents as Lifelong Learners

原文 · 2025 v3

正文范围：§3-7。

1396 实例按顺序共享经验，回放收益随任务 / 模型变化；过多历史可能降分或 OOM。Linux / A800 环境不等于本机。

对小夏：按时间串联多日场景，比较无记忆、当前检索和扩大历史；学习任务技能不等于人格成长。

小夏认知网络的理论机制与 Codex 实验设计

> v1.1 参考版：本稿保留原研究的机制、数据、阅读范围和候选实验。项目交付是不变量；算法、模型、参数、模块、训练与实验安排均可调整、组合、替换或放弃。旧代码接入点和"第一版"安排是候选建议，不构成施工边界。以项目合同 v1.1 和 README_CODEX_REFERENCE 为准。

小夏的主架构实验应沿着你提出的方向推进：LLM 承担语言理解和复杂推理，持久认知网络承载经历、概念、目标、注意状态和可学习的选择倾向。 每次真实经历不仅增加一条记录，还能改变以后怎样联想、判断和行动。

最值得先实现的组合是：经历与概念双层网络、按真实时间变化的激活、事件评价、情境化效用学习，以及快慢记忆巩固。第一版保留主 LLM，先让外部认知状态形成可观察的学习闭环。

日期：2026 年 11 月 3 日。代码对照版本为 xiaoxia 406e86e。本稿聚焦认知主干；全项目其他方向接续小夏全项目理论依据与 Codex 实现路线。

主架构与三个时间尺度

认知架构决定各部分如何共同工作；神经符号方法连接开放语言和可操作的概念关系；持续学习决定经历怎样改变将来的选择。这三个方向共同服务于同一个运行循环。

方向	在小夏中的职责	优先机制
Cognitive Architecture	组织当前情境、注意、目标、记忆和行动	ACT-R 激活、LIDA 工作状态、EMA 事件评价
Neurosymbolic AI	把语言理解连接到概念、关系和可查询状态	经历与概念图、结构化操作、时间化关系
Continual Learning	根据结果修订选择倾向和长期理解	MemRL 效用更新、CLS 巩固、代表性回放

Standard Model of the Mind 将工作记忆、陈述记忆、程序记忆和行动组织在同一框架里，并让符号关系携带激活、频率、效用等数值。LIDA 进一步区分当前激活与长期基础激活，用注意竞争决定哪些内容进入共享工作状态。这为小夏提供了结构依据：图中的关联必须参与当前选择。

状态更新的快慢

时间尺度	保存什么	何时变化
快	当前输入线索、局部激活、候选解释、工作集	新消息、阅读结果、工具结果
中	对话焦点、未完成目标、当前事件评价、跨事件 mood	情境解释变化、目标进展、时间流逝
慢	长期关联强度、可修订概括、兴趣结构、策略效用	重复经历、可归因反馈、新旧经历巩固

"快、中、慢"首先规定更新原因和相对速度，不预先把每类状态锁死为某个秒数。一次事件可以迅速改变当前反应；稳定的习惯和理解通过更长期的积累形成。

结构示意的可编辑 Mermaid 源（总图另附）：

```mermaid
flowchart TD
  E["消息 阅读 行动结果"] --> I["LLM 情境解释"]
  I --> N["持久认知网络"]
  N --> W["激活与注意工作集"]
  W --> R["LLM 推理与行动"]
  R --> E
  E --> U["反馈更新与巩固"]
  U --> N
```

工作集仍通过模型上下文传入。关键变化在于它由持续演化的状态计算产生，并与后续学习相连。LLM 可以继续检索、提出新关联和解决图中从未出现的问题。

节点 关系与状态语义

第一版使用具有业务意义的节点，不需要模拟生物神经元。核心节点是具体经历、概念和目标；行为方案可以先作为带效用的记录，后续再决定是否图化。

对象	最小内容	用途
Episode 经历	原始内容或引用、来源、发生时间、获知时间、事件 ID	保留具体语境，支持重新理解
Concept 概念	名称、语义表示、关联经历、可修订概括	连接分散的经历
Goal 目标	目标内容、相关对象、进展、当前状态	让注意与行动有连续方向
Relation 关系	两端节点、关系类型、来源、有效时间、关联强度	表示关于、支持、冲突、先后、关联目标等
Decision 决策记录	所用工作集、动作、引用的节点、结果或反馈	连接一次选择和后续学习

HippoRAG 2 的关键做法是让概念与原文段落共同进入图。其三项多跳任务消融中，完整模型的平均 Recall@5 为 87.1，去掉原文节点后为 81.0。对小夏的直接启发是：概念下面保留具体经历，检索可以沿概念找到旧事，也可以从旧事发现新的概念关联。

四类数值分别负责什么

状态	回答的问题	更新依据
activation	此刻是否容易想到它	当前线索、时间、关联传播
evidence 与 validity	这项理解由什么支持，何时成立	新观察、明确修订、来源与时间
utility	在这类情境下，用它是否有帮助	任务结果或可归因反馈
stability	这项长期模式应多快改变	经验覆盖、稳定性、反例和近期变化

这几个量应分别存储。想起一件事会增加熟悉度；新增独立观察才增加独立证据。一条失败经历也可能因为提供了好教训而有较高效用。

Zep 把经历、事实和概括连接起来，并区分事实的有效时间与系统获知时间。小夏可以据此保存“过去如此、后来改变”的关系。时间有效性负责解释现实变化，激活负责控制当前可及性，两者独立更新。

关联边也应带类型。同一次对话中出现的两个概念可以形成共现关联；“导致”“支持某结论”等关系需要各自的语义和出处。强关联首先影响联想，不自动升级为因果关系。

激活 遗忘与线索唤回

自然遗忘应成为正常动力学：久未使用的细节逐渐不易想起；合适线索能重新唤起旧事；反复使用和巩固使部分内容保持更久。

ACT-R 用基础激活和当前线索共同决定记忆的可及性：

$$A_i = B_i + \sum_j W_j S_{ji}, \quad B_i = \ln \sum_k t_k^{-d}$$

这里，t_k 是距第 k 次学习或使用经过的时间；d 控制衰减；W_j 是当前线索的注意权重，S_ji 是线索到记忆的关联强度。它把时间、复用和情境联想接到同一机制上。论文中的具体参数服务于其认知实验，小夏应在自己的情境序列上拟合。

原型中的计算步骤

1. 用词法和语义匹配找到当前输入的种子节点，同时加入相关的未完成目标。

2. 按真实经过时间计算长期基础激活，不依赖程序运行了多少个循环。实现时固定时间单位，并为刚发生的事件使用正的最小间隔。

3. 在有限子图上沿带类型的关系扩散；对高度泛化、连接过多的节点处理注意稀释。

4. 以注意预算和阈值选择工作集，保存入选原因和关系路径。

5. 当现有工作集不足以解释问题时，允许 LLM 扩展检索或形成新的候选解释。

先使用 Personalized PageRank 作为图检索基线，再在同一张图上比较带时间先验与竞争机制的动态激活，不叠加两套扩散结果。SYNAPSE 提供了经历与概念图上的扩散、fan effect、竞争和阈值方案，适合做后一组候选实现。

其中要分清三个“时间”：

• 过去使用至今的间隔，控制长期可及性。

• 两个事件之间的时间距离，控制事件邻近关系。

• 一次查询中的扩散迭代，控制激活传播与收敛。

SYNAPSE 的查询内衰减项属于第三类，其时间边权中的事件间隔属于第二类；长期遗忘仍需第一类真实时钟。让程序离线一周再启动，应与经过同样一周但没有新事件的持续运行得到相应的时间状态。

初始关联如何形成

Embedding ACT-R 用语言表示的相似度构建关联，并加入 fan 效应，说明向量语义可以接入经典激活模型。它的实证任务是词汇启动和反应时预测。工程上可以先用 embedding 提供关联先验，再让实际经历及反馈调整连接。

为避免“越被检索越垄断”，将候选命中、进入工作集、被用于一次决策、明确复习分成不同事件。候选命中不自动强化基础激活。首版按可观察的使用记录更新，保留复习来源。

细节的可及性与概括的可及性可以采用不同衰减速度。例如，一次讨论的逐字措辞淡去，讨论形成的条件性理解仍可保留。归档与存储清理是独立的容量策略。

情绪评价如何参与认知

EMA 的核心是：情绪随“这件事对目标意味着什么”的解释变化而变化。它区分情境推理和评价；解释形成后，相关性、目标促进或阻碍、结果可能性、意外、归因、可控性等维度形成 appraisal frame。情绪再影响注意和应对方式。

对小夏，LLM 负责理解事件及其与目标的关系；运行时保存这种理解和评价，使其可以持续、修订，并影响以后的选择。

最小事件评价记录

```
AppraisalFrame
  event_id
  interpretation_revision
  related_goal_ids
  relevance
  goal_congruence
  expectedness
  agency
  controllability
  resolution_state
  source_episode_ids
```

这是一份候选接口，不要求所有维度一开始都量化到很细。首版优先接通“相关目标、促进或阻碍、可控性、是否已解决”。

同一事件补充了新信息，就修订同一个 frame。事件解决后调整它对当前情绪的贡献。重新想起旧事可以改变当前体验，但应记录为一次唤回或新的解释，不能把原事件重复计成又发生了一次。

跨事件 mood 由仍有影响的评价共同形成。EMA 原文通过情绪 frames 的聚合与调整实现这一层；若工程上采用时间权重或平滑，作为独立候选与该基线比较。

下游消费

情绪状态至少影响三处，才能成为认知机制：

• 注意：哪些目标、经历和线索优先进入工作集。

• 行动：继续了解、提供帮助、换话题、稍后再提等候选如何排序。

• 表达：回应强度、节奏以及文字和语音的表达选择。

一个设计样例：最初把沉默解释为话题不合适；获得“刚才忙着处理事情”的新信息后，修订原解释，对该话题的负面判断也随之调整。关键测试是重新理解是否改变了后续选择，而不只是换了一句情绪描写。

反馈学习与快慢巩固

先学习外部选择策略

MemRL 将冻结的 LLM 与可学习的记忆选择策略分开。先召回语义相关候选，再利用效用估计选择；得到结果后更新效用。其基础更新形式之一为：

$$Q_{\text{new}} = Q_{\text{old}} + \alpha(r - Q_{\text{old}})$$

论文的留出任务平均成功率由 MemP 的 0.766 提升到 MemRL 的 0.794。它为小夏提供了直接实验入口：保持主模型，学习外部经验的选择方式。

小夏的原型将效用细化为“某经历或策略在某类情境中的帮助程度”，而不是给每段记忆永久打一个全局好坏分数。首批反馈分三类处理：

反馈	更新对象	结果解释
明确事实或偏好修订	对应关系及其有效时间	更新理解的内容

反馈	更新对象	结果解释
对主动话题的明确评价	情境化话题或时机效用	学习何时适合提及
工具任务实际结果	相应经验或行动策略效用	学习哪些方法帮助完成目标

沉默记录为反馈缺失。语义与目标相关性先限定候选，效用随后参与选择；给相关的新经历保留试用机会，以免早期高分经历长期垄断工作集。

一条回答可能涉及多个节点。记录提供给模型的节点、动作引用和可观察结果；用移除或替换关键记忆的对照检查贡献。第一版只更新能明确归因的部分，不把整个回答的奖惩广播到所有召回节点。

让具体经历形成长期理解

Complementary Learning Systems 提供快慢系统的理论基础：快速保存具体经历，通过新旧经历交错学习逐渐提取共同结构。小夏可以把它转化为两条不同速度的路径：

- 快路径保存刚发生的聊天、阅读、动作和结果，立即可供检索。
- 慢路径从多次经历提炼带条件的理解、兴趣联系和可复用方法。

一次巩固应产生可修订的概括，并关联支持经历、相反经历和适用条件。设计样例是“夜班后更偏好简短交流”，而不是无条件的“永远不喜欢长回复”。新反例进入后修订条件，既有概括仍可继续演化。

回放采样同时覆盖新经历、旧的代表经历、最近反例和正在变化的目标。回放沿用原 episode ID，次数改变熟悉度，不增加独立事实来源数。

后续可训练模块

第一版可用外部数值更新完成闭环。有足够反馈后，再训练小型相关性打分器、话题选择器或评价器。

On Tiny Episodic Memories 提供简单经验回放的强基线；EWC 用参数重要性限制破坏旧技能的更新；MER 通过新旧梯度的相容性兼顾迁移与干扰。它们进入小模块训练的对照组，不必套进首版 Q 表。

如果后续需要把延迟反馈分配到关联边，可研究三因素学习中的 eligibility trace。Frémaux 与 Gerstner 的理论综述描述了局部活动痕迹与后续调制信号的结合。候选局部规则为：

$$\Delta w_{ij} = \eta \, \delta_t \, e_{ij}(t)$$

e_ij 标记近期参与的连接，delta 表示相对同类情境预期的结果。应用顺序是先检验记忆选择效用，再研究边的信用分配；不要同时开放全部参数，以免实验无法定位改善来自哪里。

神经符号接口怎样保留 LLM 的能力

NS-CL 将神经表示、语义解析与可组合操作连接起来，并通过任务结果训练概念对应关系。对小夏，值得借用的是这一接口思想：LLM 将开放语言解释为候选经历、关系、目标与操作，网络提供持久状态及结构查询，复杂推理和自然表达继续由 LLM 完成。

初始操作可以很少：查找经历、追踪来源、关联概念、修订关系、更新目标、提交反馈。概念和关系的内容保持开放，不要求开发者提前列出所有话题。

需要明确组合推理的局部问题再考虑 Logical Neural Networks。其节点对应逻辑式，数值表示真值边界和连接作用，可以进行双向推理与学习。适合探索条件组合和冲突解释，不作为普通聊天每句话的强制通道。

给强模型留出的空间

- 工作集是当前材料和选择倾向，模型仍可以提出新解释。

• 现有网络没有答案时，允许补充检索、推理和创建候选关联。

• 行为方案先作为可选经验，而非逐句话术模板。

• 自由文本、原始经历与结构化关系并存，避免在建图时丢掉语境。

• 在预算相同的实验中比较网络是否帮助了强模型，保留它原本擅长的新问题推理。

这一分工允许理论规定"状态如何形成和更新"，让模型继续发挥"怎样理解眼前新问题"的能力。

现有代码的接入位置

下列判断对应固定版本 406e86e，文件位于 data/plugins/astrbot_plugin_ada_companion/。

代码位置	已有行为	认知原型接入方式
temper.py	根据当前消息及最近回复生成少量当轮表达提示	新增持久 appraisal 与 mood；现有提示作为对照，不把它当长期情绪存储
prompting.py	ContextBuilder 组合材料、共享历史、记忆，并以临时 TextPart 加入 temper 提示	让工作集投影进入已有上下文构建路径
owner_memory.py	维护跨渠道身份，按原生 scope 调用记忆桥接并组合历史	保留身份与来源逻辑，认知状态放入记忆状态层
main.py	已装配 DialogueState、MemoryTools、ContextBuilder、ProactiveChat 和 InterestMaterials	在既有装配点接入一个认知运行时，不另建一套主动调度
initiative.py 与 initiative_materials.py	主动决策使用线程、记忆和阅读材料，发送前复核当前状态	从认知网络获取目标及候选排序，继续由现有执行链消费

owner-links.json 承担身份链接，不能充当认知图。项目已经有 astrbot_plugin_memory_companion 及记忆桥接，具体持久化位置应沿该层现有存储确认，避免产生第二份互不一致的记忆权威。

最小接口提案

```
observe(event, interpretation=None) -> StateDelta
activate(cues, state, now, budget) -> Workspace
feedback(decision_id, outcome) -> LearningDelta
consolidate(episode_ids, state, now) -> StateDelta
```

这些是逻辑接口，第一版可以处于一个小模块中。

Workspace 至少包含选中的经历与概念、相关目标、简短评价状态、来源和选择分量。StateDelta 记录针对哪个事件、哪一版状态的更新。相同事件再次送达时读取已有结果，不重复强化。

一次交互如何运行

1. 保存真实输入及事件 ID，用已有语义表示产生初步线索。

2. 从现有状态激活工作集，交给主 LLM。

3. LLM 结合新输入解释情境、推理和回应；需要更多材料时使用检索操作。

4. 将结构化解释、目标变化及可观察动作写入认知状态。

5. 后续真实结果通过决策 ID 更新相应效用。

6. 空闲时选取新旧经历巩固，产出新的概括版本。

需要当轮重新检索的复杂事件，可以在解释后再激活一次。简单回复不强制增加第二次模型调用，更不为每个图节点发起 LLM 调用。

原型只在相关子图上计算，显式配置活动节点、扩散步数、上下文和后台巩固预算。先测量这些量的影响，再决定具体阈值和存储优化。

对照实验与验收

研究问题是：长期内部状态的变化，是否持续改善小夏的注意、联想、理解和行动？

固定主模型版本、系统模板、输入序列和上下文预算。每个情境家族分为开发版本与留出版本，留出版本改写措辞或更换表面主题；记录随机设置和状态快照。

组别	增加的机制	回答的问题
A	现有上下文与记忆路径	当前能力基线
B	同一材料的经历与概念图，加 PPR	结构关联是否有用
C	同图改用真实时间先验与动态激活	自然遗忘与线索唤回是否改善选择
D	C 上增加情境化效用学习	结果反馈是否改善后续选择
E	D 上增加新旧混合巩固	是否形成可迁移、可修订的长期理解

情绪评价单独做开关对照，分别放在 C 或 D 上比较。不要让一次版本同时增加情绪、模型大小、上下文和记忆容量。

八类核心情境

情境	观察什么	实现上的判据
自然遗忘	细节随间隔降低可及性，重要概括保持更久	用可控时钟比较曲线；关机期间按实际经过时间演化
线索唤回	无直接关键词时能否通过经历和概念找到旧事	同时检查正确关联与无关串联
解释修订	新信息改变对同一事件的理解	原 appraisal 修订，后续注意或行动随之变化
反馈学习	以前无效的选择是否减少	改善出现在相似的新情境，不只原句重放
条件性巩固	多次经历能否形成有条件的概括	新反例能修订适用范围
事实变化	过去与当前关系是否正确使用	时间问题得到相应版本
状态恢复	已学倾向是否跨重启延续	恢复快照延续，重置快照消失；重复事件只学习一次
开放新题	网络没有已有模式时能否正常推理	与同模型基线比较完成质量和额外开销

设计样例：歌曲线索连接到一次具体聊天，再连接到当时尚未完成的计划。改变歌曲表述仍能找到这条经历；一个只有相同音乐词汇、没有共同经历的输入，不应强行触发同一计划。评价的是有理由的关联。

必须同时记录的结果

记录候选集、工作集、相关目标、采用的来源、动作、结果以及状态变化；这些是可观察的决策证据，不要求保存模型的私有推理过程。

质量指标包括跨经历关联正确性、无关关联率、新情境迁移、事实修订使用、主动话题适切性。工程指标包括端到端和新增 P95 延迟、模型调用量、活动子图大小、长期存储增长及恢复一致性。

先用小批量人工逐例复核发现机制问题，再扩大到足够多的独立情境；对随机生成做重复试验，报告差值及不确定性。是否晋升由目标能力、旧能力保持和资源成本共同决定。遗忘相关指标按线索强弱、时间和记忆类型分组，不以“所有细节永久答对”作为目标。

论文阅读索引与采用顺序

以下 16 项对应原文的方法、相关公式、实验或理论论证。前十项支撑首轮认知原型；后六项用于接口比较与下一阶段学习机制。

认知主干与记忆机制

论文	核读位置	小夏应取用的部分
An Integrated Theory of the Mind，2004，链接为作者早期稿	陈述记忆、激活方程、fan effect、规则效用	时间与复用形成基础激活，当前线索驱动联想
LIDA A Systems-level Architecture for Cognition Emotion and Learning，2014	III、VI、VII、VIII、X	当前与长期激活、注意竞争、共享工作状态；情绪学习部分含概念设计
EMA A process model of appraisal dynamics，2009	2.3.2-2.3.5	解释、评价、mood、注意与应对的循环
A Standard Model of the Mind，2017	Structure and Processing、Memory and Content、Learning	符号关系与可学习数值状态的组织方式
Integrating language model embeddings into the ACT-R cognitive modeling framework，2026	2.2-2.3 与结果部分	向量语义接入关联强度；实证为词汇启动任务
From RAG to Memory，HippoRAG 2，ICML 2025	3-6、附录 G、表 4	概念和原文共同入图，PPR 作为联想基线
Zep A Temporal Knowledge Graph Architecture for Agent Memory，2025	2-4	来源关系、有效时间与获知时间
Synapse Empowering LLM Agents with Episodic-Semantic Memory via Spreading Activation，2026 预印本	3.1-3.4、4.3	动态扩散、竞争、阈值；与时间先验分开验证
Why There Are Complementary Learning Systems in the Hippocampus and Neocortex，1995	快慢学习、交错训练、巩固论证	经历快速保存，长期结构逐步形成
MemRL Self-Evolving Agents via Runtime Reinforcement Learning on Episodic Memory，2026 预印本	3-5、附录 A、G.1-G.2	冻结主 LLM 的外部效用学习；多记忆信用分配是需继续细化的点

神经符号与后续学习方法

论文	核读位置	采用条件
The Neuro-Symbolic Concept Learner，ICLR 2019	3.1-3.2、4.1-4.2	借用语言到可组合概念操作的接口，原实验为视觉推理
Logical Neural Networks，2020	3-4、6-7	局部条件组合、真值边界和软逻辑实验
Overcoming catastrophic forgetting in neural networks，PNAS 2017	参数重要性方法、公式 3、顺序任务实验	有可训练小模块后比较重要参数保护
Learning to Learn without Forgetting by Maximizing Transfer and Minimizing Interference，ICLR 2019	2-3、Algorithm 1、实验	研究新旧梯度的迁移与干扰
On Tiny Episodic Memories in Continual Learning，2019	3-5	小型代表性回放作为训练强基线
Neuromodulated Spike-Timing-Dependent Plasticity and Theory of Three-Factor Learning Rules，2016 理论综述	4-5，尤其 eligibility trace 与延迟反馈	后续关联边信用分配的机制来源

Codex 第一轮任务

先交付一个能跑完整因果链的原型：同一主模型、同一系统模板，因为经历不同，产生不同且有理由的工作集和选择；反馈改变下一次选择；状态恢复后这种变化仍然存在。

实现顺序是经历与概念图、激活和时间、工作集接入、明确反馈驱动的效用更新。并行建立事件解释与 appraisal 的状态结构；在独立对照里接入注意和行为。最后加入新旧经历巩固，比较是否带来跨情境迁移。

交付内容应包括：

1. 最小状态模型及四个接口，接在现有记忆和上下文路径。

2. 一个跨多次交互的可运行情境，展示状态如何改变注意与选择。

3. 可控时钟、快照恢复、事件去重和 appraisal 修订测试。

4. A 至 E 的同预算对照，以及至少一组模块关闭实验。

5. 每项改善对应哪条机制、哪些情境受益、资源增加多少的结果说明。

框架、数据库和模型选型由现有代码与实验结果决定。首轮的交付重点是让经历真正参与后续认知；后续再按结果选择可训练排序器、局部软逻辑或更细的关联学习。

小夏语音与聊天专项：顶会论文、候选架构与 Codex 实验

v1.1 参考版：本稿保留原研究的机制、数据、阅读范围和候选实验。项目交付是不变量；算法、模型、参数、模块、训练与实验安排均可调整、组合、替换或放弃。旧代码接入点和"第一版"安排是候选建议，不构成施工边界。以项目合同 v1.1 和 README_CODEX_REFERENCE 为准。

更新：2026-11-04。面向小夏的语音与聊天专项。核心清单为 28 篇正式会议论文：27 篇发表于 2023-2026 年，另有 1 篇 ACL 2020 基础工作；其中 11 篇发表于 2026 年。覆盖 ACL、EMNLP、NAACL、ICLR、ICML、NeurIPS、AAAI，ACL Short 单独标明。现有代码、TTS 引擎和模型组合均作为候选，不预设保留。

方向判断

小夏值得追求的是：理解对方正在做什么，结合共同经历形成自己的回应，再以连贯的声音和合适的时机说出来。

综合这些论文，我建议把研究重点放在语义与声音联合表达、持续运行的互动控制，以及由真实对话反馈改善的生成策略。认知网络提供长期状态和经历，强语言模型负责理解与组织，语音系统保留并表达文字之外的信息。最终实现可以是模块化、混合模型或原生语音模型。

最有分量的机制证据有五组：

1. 保留语义支撑。 OmniFlatten 与 LLaMA-Omni 2 的消融都显示，移除文本相关通路会损害语音回答。它们支持研究文本 / 语义与声音的耦合接口，而不是把"端到端"理解成必须消灭所有中间表征。P21、P22

2. 稳定身份与灵活表达分开。 NaturalSpeech 3、PromptTTS 2 和 IndexTTS2 分别研究音色、韵律、内容及描述条件的解耦。小夏可以保持同一声音，同时让重音、语速、停连和情绪强度随语境变化。P10、P11、P13

3. 互动时机需要独立学习。 Talking Turns 定义互动事件；Multi-Faceted Interactivity Alignment 对等待、接话、附和、插话分别优化。这是实时对话能力的一条直接训练路径。P19、P17

4. 自然聊天依赖语境适切性。 SCONPOS 处理人设过用，DialogGRPO 学习有价值的澄清，SODA 用具体情境生成社交对话，EmoCharacter 检查情绪是否由经历与当前事件驱动。P01、P02、P03、P04

5. 评价对象必须包含完整交互。 声音表达用音频盲听，多轮语义用状态与约束检查，抢话和打断用连续双向流。各项各有判据，共同决定路线选择。P18、P26、P27

三条候选路线

路线	工作方式与优势	最需要验证的能力	第一轮研究对象
A 强语言模型加可控语音	文字、声学线索、记忆共同进入强 LLM；语音独立生成；实时控制并行运行。模型与声音可分别升级	语气信息传递是否充分；分句是否自然；推理与 TTS 的合计等待	相同强 LLM，比较 IndexTTS 系列、F5 类分句生成及真正流式解码
B 语义与语音耦合	语音编码器连接语言底座，文字与隐藏表示共同驱动流式声音；保留明确语义支撑	能否兼顾复杂回应、细腻表达、固定声音和低等待	Freeze-Omni、LLaMA-Omni 2 双语版本；开放模型内部接口的适配实验
C 原生全双工	模型持续接收和生成音频，在时间序列上学习听、说、附和与让话	中文与中英混合、长期状态、声音身份，以及多人声重叠时的语义保持	Moshi / PersonaPlex 及四轴 RL checkpoint；GLM-4-Voice 作语音知识对照；OmniFlatten 作训练设计参考

我的研究优先级：重点验证 B 的语义-语音耦合机制，同时让 A 提供强内容与声音控制的基准，让 C 充分展示实时互动优势。 三条路线都保留获选资格。能力评估先允许各模型发挥其原生能力；随后再统一部署预算与延迟约束，决定产品采用哪条。

这三条是实验原型，不是互斥的理论类别：全双工描述互动方式，语义耦合描述表示与训练设计；B 可以扩展为全双工，C 也可以保留文本流。语义支撑可以是文字、连续隐藏表示或联合 token，具体形式由实验决定，无需规定每轮先写完一整段文字。

B 的 hidden-state 版本需要模型内部表示及适配训练；只有文字 API 的“文本 / 表达意图 + 语音”实验属于另一种可测接口，应分别报告。C 中部分公开模型主要面向英语，应先用中文实测判断。大型预训练工作的价值在于架构与现有 checkpoint，不要求小夏重做其全部训练。

认知网络如何进入聊天和声音

建议分清四种状态，它们可以在一个模型内部实现，也可以由多个组件承载：

状态	应提供的信息	应影响的行为
长期认知状态	自身稳定倾向、关系经历、已经形成的观点、用户目标和记忆来源	什么值得注意、如何理解这次交流、哪些经历自然相关
当前互动状态	用户是在分享、玩笑、求助、纠正还是转题；是否仍在说话；哪些话题尚未完成	此刻是否回应、回应重点、是否追问、是否先听
表达意图	这句话是解释、安慰、调侃、认真提醒还是简短回应	措辞、重音、节奏、情绪强度和停连
交付状态	哪些文字已显示、哪些音频已播放、哪些内容被打断而未送达	后续续聊、纠正、记忆更新与播放取消

内部情绪和外显语气需要一个可学习的映射。例如关心对方，可能表现为轻声询问，也可能表现为简短而明确的建议。把内部“关心强度”直接换成统一的柔声标签，会丢掉交际意图。

下面表示能力关系，不规定服务数量或进程划分：

结构示意的可编辑 Mermaid 源（总图另附）：

```
flowchart TD
  U["用户语音或文字"] --> P["流式理解与声学线索"]
  P --> I["实时互动控制"]
  P --> R["语义与表达规划"]
  S["认知状态与记忆"] <--> R
  R --> V["语音生成"]
  R --> T["屏幕文字"]
  V --> O["实际播放"]
  I --> O
  O --> E["已播放与已显示记录"]
  T --> E
  E --> S
```

文字与音频应使用同一套版本化状态归并规则；识别假设、用户表达、系统计划和实际呈现分别记录，识别中的每次局部改写不直接更新长期记忆。两种输出保留各自交付记录：用户打断时，已生成但尚未播出的半段回答，不能在下一轮被当成已经通过语音讲完。如果文字已经显示，则保留它的文字交付事实。这是本专项建议加入的工程机制。

实时互动控制只决定等待、附和、接话、让话和取消等时机，不替语言模型预先编写每类情绪的固定句式。表达计划可以保留自然语言描述；只有需要精确执行的发音、片段边界、播放代次等内容才结构化。

聊天生成与长期承接

以下研究卡均区分论文机制、论文实验和建议给小夏做的迁移实验。数字用于理解原实验，不用于跨论文排模型名次。

P01 | 人格适切性：SCONPOS

Controlling and Assessing Appropriate Persona Use in LLM-based Dialogue Generation - EMNLP 2026 主会。 出版页 · 全文 · 代码

机制：比较“全部人设”和“当前语境相关人设”的隐藏激活，得到过度使用人设的方向；推理时在特定层减去该方向，模型权重保持冻结。实验中，人评人格使用适切性胜率为 76%，连贯性为 68%，每组 50 对回复、3 位评审。其自动 PAS 指标与人评相关性较弱，不适合独立裁决体验。

小夏实验： 完整人设常驻、稳定身份 + 相关经历激活、开权重 activation steering 三组对照。既测不抢着介绍自己，也测被问到时仍有稳定观点。steering 需要内部激活访问；语境化记忆组织则可用于 API 模型。

阅读：§2-5，表 2/3/6/7，附录 B/C。

P02 | 有价值的追问：DialogGRPO

Don’t Guess, Ask Wisely: Benchmarking and Training Proactive Elicitation in Open-Domain LLM Conversations - EMNLP 2026 主会。 出版页 · 全文

机制：从完整请求构造信息缺失版本，离线展开候选追问；以信息增益、后续回答收益和交互成本训练提问策略。Qwen3.5-27B 在完整请求上仍追问的比例为 5.2%，简单“鼓励追问”提示为 42.8%；在两类模糊请求上则积极补齐信息。实验主要使用英文请求和模拟用户。

小夏实验： 区分真正好奇、必要澄清、重复询问和机械续聊。优化“问完是否让交流更好”，不要优化提问数量。分享、玩笑和观点交流另设标准，不统一变成信息收集任务。

阅读：§3.3-5.2，表 2/3及消融。

P03 | 情境化社交数据：SODA

SODA: Million-scale Dialogue Distillation with Social Commonsense Contextualization - EMNLP 2023 主会。 出版页 · 全文 · 作者项目

机制：社会常识关系生成具体情境，再生成多轮对话；150 万条对话用于训练 COSMO，训练中随机丢弃部分情境与角色提示。未见 DailyDialog 上，COSMO-3B 相对 Vicuna-7B 的自然度人评胜率为 58%。重点是数据构造方法，不是沿用旧模型排名。

小夏实验： 用事件、关系、各自掌握的信息、各自在意的事情生成中文场景；同场景比较自然接话、客服建议、机械共情、过度解释。把自然性放进训练与偏好数据，而不只写“请自然一点”。

阅读：§2-5，表 5-7及人评设置。

P04 | 情绪随事件变化：EmoCharacter

EmoCharacter: Evaluating the Emotional Fidelity of Role-Playing Agents in Dialogues - NAACL 2025 主会。 出版页 · 全文

机制：以《老友记》剧本构造角色对话，评价情绪一致性、角色差异与情绪转移，并实验情绪-回复联合微调。GPT-4o 无角色提示的情绪一致性为 .484，加入 RoleLLM 提示后为 .422；Llama3-8B 通过联合样本微调由 .408 提升到 .499。研究对象是文本角色与情绪标签。

小夏实验： 固定人格，改变当前事件；固定事件，改变共同经历。检查情绪变化是否有来由。“温柔”不要求永远柔声，“乐观”也不要求遇到坏事立刻积极总结。

阅读：§3-5，表 2-5。

P05 | 对话偏好评价：AMULET

AMULET: Putting Complex Multi-Turn Conversations on the Stand with LLM Juries - EMNLP 2025 主会。 出版页 · 全文

机制：分别按对话行为和会话准则评判候选，交换候选顺序双投票，分歧时再裁决。GPT-4o 的偏好判别准确率在 HH-TEST 由 55.7% 到 64.1%，WildFeedback 由 75.1% 到 80.2%。它评价多轮历史末尾的一对候选回复。

小夏实验： 用于离线回归和偏好样本筛选，检查回复是否接住分享、求助、纠正或玩笑。行为标签用于评价，不规定固定句式；实时语音不必额外串行经过一组裁判。

阅读：§2-4，表 2-4。

P06 | 记忆索引与原始证据：LongMemEval

LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory - ICLR 2025。 出版页 · 全文 · 代码

机制：分解索引、检索、读取；用抽取事实增强轮次检索 key，保留原始轮次作为证据，结合时间查询。其事实增强索引使 Recall@10 从 .692 到 .784，问答成绩从 .670 到 .720。单纯替换原文为摘要会损失细节。

小夏实验： 摘要检索与“浓缩索引 + 可读回原对话”比较；覆盖偏好更新、时间指代、玩笑、说话人归属。自然遗忘可以表现为激活降低和细节降级；被检索出来的记忆保留其来源。

阅读：§4-5，表 3/4，附录 D/E。

P07 | 无提示的认知记忆：Locomo-Plus

Locomo-Plus: Beyond-Factual Cognitive Memory Evaluation Framework for LLM Agents - ACL 2026 主会。 出版页 · 全文 · 代码

机制：较早对话给出目标、状态、价值或因果背景，之后用词面不相似的话题触发，按相关约束是否被遵守评价。实验中 GPT-4o 的事实记忆平均分 62.99，认知记忆为 21.05；纯语义 top-5 检索仍有明显困难。

小夏实验： 看她能否在没被提醒“你记得吗”时自然用到相关经历；同时加入目标已改变的配对反例。评价该关联时关联、不相关时不翻旧账。

阅读：§3-6，表 1-3。

P08 | 人格、知识、共情的融合：BlendedSkillTalk

Can You Put it All Together: Evaluating Conversational Agents' Ability to Blend Skills - ACL 2020 主会，经典基础。 出版页 · 全文

机制：联合训练人格、知识与共情，再用混合技能真人对话微调；与单技能、切换和路由方案比较。真人总体质量评分，单技能约 2.6-3.0/5，联合训练并 BST 微调达到 3.6/5。模型属于当时的检索式系统。

小夏实验： 一段对话里顺畅地聊兴趣、表达心情、解释知识、开玩笑，仍保持同一交流风格。借鉴融合能力的训练目标和数据组织，不照搬 2020 年模型。

阅读：§3-4，表 4/5/7。

声音身份与自然表达

P09 | 可变化的表达风格：StyleTTS 2

StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models - NeurIPS 2023 主会。 出版页 · 全文 · 代码

机制：文本条件下生成风格向量，声学风格和韵律分别编码，用语音语言模型特征构造判别器。LJSpeech 域外文本消融中，去除风格扩散使自然度 CMOS 降 .46，去除韵律编码器降 .35。

小夏实验： 同一身份下比较相邻五句话的韵律变化、自然度和风格连续性。既避免机械重复，也避免每句像换了一个人。公开模型主要是英语，中文适配单独计入方案。

阅读：§3.2、§4、§5.2-5.3。

P10 | 音色、韵律、内容解耦：NaturalSpeech 3

NaturalSpeech 3: Zero-Shot Speech Synthesis with Factorized Codec and Diffusion Models - ICML 2024。 出版页 · 作者全文

机制：FACodec 分离内容、韵律、音色和声学细节，通过信息瓶颈、监督、梯度反转及细节 dropout 学到分工；生成器分别建模。去掉 factorization 后，Sim-O 从 .67 降到 .55，WER 从 1.81 到 2.49，SMOS 从 4.01 到 3.59。实验使用 60K 小时英语训练。

小夏实验： 固定音色表示，改变韵律、内容或时长，检测独立控制是否成立。创建几个字段只是接口设计，真正解耦还要模型表示与训练支持。官方公开 FACodec；完整生成路线需另做集成与训练核验。

阅读：§3、§4.1/4.3，附录 A.5-A.6。

P11 | 自然语言控制声音：PromptTTS 2

PromptTTS 2: Describing and Generating Voices with Text Prompt - ICLR 2024。 出版页 · 全文 · 作者项目

机制：将提示明确指定的属性与未指定的变化分开，后者由 diffusion variation network 建模，条件经 cross-attention 进入声音生成。在 1,305 条英语提示上，性别、速度、音量、音高平均控制准确率为 93.33%，对照为 91.54%。

小夏实验： “小声一点”“轻一点”等同意图改写应产生接近的表达；未要求变化的声音身份保持稳定。该机制需要相应条件模块训练，本轮未核到完整官方可部署权重。

阅读：§3.1-3.3、§4、§5.1-5.3。

P12 | 连续情绪强度：EmoKnob

EmoKnob: Enhance Voice Cloning with Fine-Grained Emotion Control - EMNLP 2024 主会。 出版页 · 全文 · 作者项目

机制：从同说话人情绪/中性样本的 embedding 差学习方向，向目标条件加上连续强度的偏移。无需重训，但要访问 embedding。23 位听者的实验中，六类情绪强度辨别平均为 86%；不同情绪的有效性差异很大，增大强度也会影响发音与身份保持。

小夏实验： 扫描低强度区间，分别评价温和、轻微高兴、迟疑和认真。目标是语境合适、自然可察觉，而不是情绪分类器分数最大。

阅读：§3-5。

P13 | 固定声线与情绪分离：IndexTTS2

IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech - AAAI 2026 主会。 出版页 · 正式 PDF · 作者全文 · 官方实现

机制：音色和情绪参考分开编码，通过梯度反转抑制身份信息泄漏；将 GPT latent 融入声音生成，帮助强情绪时保持清晰。情绪测试中，去掉 GPT latent 的 WER 从 1.883% 升至 2.766%。

小夏实验： 固定声音，比较情绪参考音频、自然语言描述、向量强度控制。选择平静关心、克制高兴、稍有犹豫等日常状态。AAAI 论文对应 v2；当前仓库的 v2.5 是后续版本。v2 发布时未启用的时长能力，不能从论文标题直接算作当时的现成功能。

阅读：T2S、三阶段训练、S2M、T2E、实验表 2/3。正式元数据由 AAAI 索引核实，方法读取作者全文。

P14 | 非自回归语音生成：F5-TTS

F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching - ACL 2025 主会。 出版页 · 全文 · 官方实现

机制：flow matching 与 DiT 生成声音，ConvNeXt 细化文本表示以改善对齐，Sway Sampling 调整采样步分布。LibriSpeech-PC 上，16 步时 WER 2.53%、RTF .15；32 步时 WER 2.42%、RTF .31。RTF 来自 RTX 3090 生成 10 秒音频的总耗时比例。

小夏实验： 比较短句、完整语义分句和长段生成；同时测首音、语义停连、漏字、句间接缝及总耗时。RTF .15 不能直接换算成首音 150 ms。官方有中英权重；代码与权重许可不同。

阅读：§3.1-3.2、§5.1、表 1及采样分析。

P15 | 声音上下文连续性：VoiceCraft

VoiceCraft: Zero-Shot Speech Editing and Text-to-Speech in the Wild - ACL 2024 主会。 出版页 · 全文 · 官方实现

机制：用 causal masking 重排语音 token，结合前后声音补全局部内容，以 delayed stacking 处理 codec 层。310 条真实编辑样本中，自然度 MOS 为 4.03，对照为 3.81，原音为 4.17；编辑实验包含十候选筛选的计算预算。

小夏实验： 借鉴声学上下文条件化，比较新句是否承接上一段实际播放的声音、打断后重新表达是否连续。论文模型主要面向英语，双向补全机制与实时因果流式输出应分别实现和测试。

阅读：§3、§5.1/5.3/5.4。

P16 | 针对发音失败的偏好学习

Advancing Zero-shot Text-to-Speech Intelligibility across Diverse Domains via Preference Alignment - ACL 2025 主会。 出版页 · 全文 · 作者项目

机制：用同模型多采样、跨模型比较和知识引导扰动构造偏好对，分别适配 AR、flow matching 和 masked generation 的 DPO。F5-TTS 四类测试平均 WER 从 17.78 降到 9.62，同时声纹相似度从 .615 到 .591；训练采用 8 张 H100。

小夏实验： 收集人名、多音字、数字、否定词、中英混合的真实错读与正确对照，再做定向训练。验收同时保留内容、音色和自然度，避免只改善可懂度却改坏声音。

阅读：§3-5，附录 D/F。

实时互动与语义语音融合

P17 | 四类互动行为的强化学习

Multi-Faceted Interactivity Alignment in Full-Duplex Speech Models - EMNLP 2026 主会。 出版页 · 全文 · Moshi RL 权重 · PersonaPlex RL 权重

机制：从真人双声道对话抽取犹豫停顿、话轮交接、附和、用户插话，分别设计 GRPO 奖励，并加入内容质量约束。Moshi 在 FDB-v1 的插话后响应从 1.377 s 到 .409 s；起点是用户插话说完，终点是系统新回答开口。训练使用 32 张 H100。

小夏实验： 先比较公开基础与 RL checkpoint；分别测等待、有效附和、让话、纠正后的回答。客户端停掉旧声音的延迟要另外记录。英语研究权重先用于机制验证，再考察中文迁移。

阅读：§3.2-5。

P18 | 连续双向流测试：Full-Duplex-Bench-v2

Full-Duplex-Bench-v2: A Multi-Turn Evaluation Framework for Duplex Dialogue Systems with an Automated Examiner - ACL 2026 主会短文。 出版页 · 全文 · 代码

机制：语音 Examiner 带着阶段目标连续交谈，Fast 主动插话、Slow 等待，测试日常交流、纠正与实体追踪等。统一 WebRTC adapter 可比较不同模型结构。Moshi 实体追踪 Fast 2.76/5、Slow 3.84/5，显示互动节奏会改变内容表现。

小夏实验： 复用连续交互测试思想，增加中文日期、对象、指代和连续改口。论文的 48 kHz、16-bit、mono、10 ms 帧是测试协议，产品采样配置可另外决定。增加扬声器与麦克风的真实声学闭环。

阅读：§2.1-2.4、§3及附录。

P19 | 什么时候轮到谁说：Talking Turns

Talking Turns: Benchmarking Audio Foundation Models on Turn-Taking Dynamics - ICLR 2025。 出版页 · 全文 · 实现入口

机制：用历史音频在 40 ms 粒度预测继续、附和、插话、换人、静默等互动事件，模型采用 Whisper 编码器与预测头。它把“声音重叠发生了多少”拆成“这次重叠是否合适”，从而区分支持性附和和抢话。

小夏实验： 同一句“嗯”在不同场景可能是附和，也可能表示要说话；短促的“不！”可能是明确纠正。结合语音、时序与语境判断，不用“有人声就取消”或一个固定静音阈值包办互动。

阅读：§3.2、§4.1-4.8、§7及用户研究。

P20 | 冻结语言底座、学习语音接口：Freeze-Omni

Freeze-Omni: A Smart and Low Latency Speech-to-speech Dialogue Model with Frozen LLM - ICML 2025。 出版页 · 作者全文 v5 · 官方实现

机制：冻结文本 LLM，训练流式音频编码器、适配器与解码器，利用 hidden states、prefix KV-cache 和块级听说状态。Web Questions 语音输入准确率为 44.73%，原文本底座为 45.13%。论文响应统计从进入生成状态计时，端点判断另有耗时。

小夏实验： 验证强文本模型的知识与推理能否经学习后的语音接口保持。该方案需要内部表示；训练用到大量内部 ASR 数据和合成语音，优先研究现成权重与小规模适配，不安排重做全部预训练。

阅读：作者版 §2、§3.1/3.4/3.5；会场由正式出版页核实。

P21 | 文本与隐藏状态门控：LLaMA-Omni 2

LLaMA-Omni 2: LLM-based Real-time Spoken Chatbot with Autoregressive Streaming Speech Synthesis - ACL 2025 主会。 出版页 · 全文 · 官方实现

机制：LLM hidden states 与实际采样的文字 token embedding 门控融合，按读写块流式生成声音。去掉文字 embedding 后，ASR-WER 从 3.26 到 6.83，语音回答分从 4.15 到 3.88。7B 在单 L40 上首语音块为 582.91 ms。

小夏实验： 研究中文语义完整性与流式表达，分别比较明确文字、隐藏状态及二者联合的作用。仓库现有 0.5B-32B 双语版本，论文原表主要对应英语版本。流式输出与持续监听、让话需要分项验证。

阅读：§2-5，重点消融表。

P22 | 统一时间序列的全双工：OmniFlatten

OmniFlatten: An End-to-end GPT Model for Seamless Voice Conversation - ACL 2025 主会。 出版页 · 全文 · 作者演示

机制：把用户音频、助手文字、助手音频分块交错为一个序列，逐步训练模态对齐、半双工和全双工。在相同 0.5B 设置中，三流版本英语/中文回答评分为 3.92/5.15（十分制）；去掉助手文字变为 2.19/3.06。

小夏实验： 保留语义支撑的原生双工与其他表示做对照。这个消融说明特定训练配置里的文本流有用，并不要求所有候选都先写完文字再说话。作者演示可读，本轮未核到正式模型与训练代码发布。

阅读：§3-4，表 3/4。

P23 | 让语音调用文本知识：交错预训练

Scaling Speech-Text Pre-training with Synthetic Interleaved Data - ICLR 2025。 出版页 · 全文 · GLM-4-Voice 实现

机制：ASR 监督语音 tokenizer，直接合成 speech token，交错文本与语音训练以打通知识使用。9B 在 Llama Questions 的 S2S 准确率为 50.7%，移除交错数据后为 2.3%。训练总量为 1T token，其中 600B 为合成交错数据。

小夏实验： 采用公开中英 checkpoint 比较文字通道与语音通道的回答，定位知识是否顺利进入声音。该论文提供预训练机制依据，不建议小夏复刻万亿 token 训练。

阅读：§2.1-2.4、§3.1-3.3。

P24 | 边听边检索：Stream RAG

Stream RAG: Instant and Accurate Spoken Dialogue Systems with Streaming Tool Usage - ICML 2026。 出版页 · 作者全文 v1

机制：利用用户尚未说完时的输入做预检索；可按间隔查询，也可学习是否查询，缓存结果并在完整请求到来后修正。训练中加入先前错误查询，使模型学会撤销过早理解。正式版与作者 v1 的实验数值有更新，本报告仅采用已读方法，不混用数值。

小夏实验： 对相关记忆和只读知识检索做受预算控制的预取；用户后半句改了日期或对象，就更新查询并停止采用旧结果。比较端点后才检索与流式检索的有意义回答等待、工具次数及错误结果使用率。

阅读：作者版 §3-5；正式会场由 PMLR 核实。

语气理解与整体评测

P25 | 文字之外的信息：Prosody and Text

What Do Prosody and Text Convey? Characterizing How Meaningful Information is Distributed Across Multiple Channels - ACL 2026 主会。 出版页 · 全文

机制：以单句英语情绪和讽刺数据，比较文字与声音分类器，并估计不同通道提供的信息。实验显示，音频携带相当一部分转写未保留的情绪及讽刺线索。任务、上下文长度和分类器影响具体估计，不把其比值外推为普遍规律。

小夏实验： 同一文字配不同语调、停顿与重音，比较仅转写、转写加声学表示、直接音频理解。判据是回应是否考虑了有意义的声学线索；有歧义的语气允许多种合理反应，不强制输出唯一情绪标签。

阅读：方法、通道比较与实验讨论。

P26 | 多轮语音中的语义保持：Audio MultiChallenge

Audio MultiChallenge: A Multi-Turn Evaluation of Spoken Dialogue Systems on Natural Human Interaction - ACL 2026 主会。 出版页 · 全文

机制：452 段真人英语对话、47 名说话人、约 15 小时，覆盖推理记忆、指令保持、自洽和口头改口，使用细粒度 rubric 评价。协议给模型相同历史用户音频与助手文字，再生成最终回复，因此适合隔离语义问题。

小夏实验： 中文“明天……不，后天”、先否定后修改、跨轮约束与口头省略。固定历史回放用于定位问题；连续真人或自适应 Examiner 对话用于检验实际交互，两者同时保留。

阅读：数据构造、四类任务、评测协议及结果。

P27 | 直接评价声音表达：S2S-Arena

S2S-Arena: Evaluating Paralinguistic Instruction Following in Speech-to-Speech Models - ACL 2026 主会。 出版页 · 全文

机制：将语义理解、语气感知、声音表达及二者结合分层测试；1,243 条样本包含约四分之一中文，以直接音频成对比较评价。人机裁判一致性约 82.87%；论文的模型集合主要来自 2023-2025 年。

小夏实验： 听原始声音分别评内容、语气适切性、自然度与声线；配对评价允许平局。使用其任务分层，不把旧模型排名当作当前选型答案，也不把转写流畅度当作声音自然度。

阅读：任务定义、样本构造、比赛与裁判验证。

P28 | 中文真实口语与跨模态：RealTalk-CN

RealTalk-CN: A Realistic Chinese Speech Task-Oriented Dialogue Benchmark with Cross-Modal Analysis - ACL 2026 主会。 出版页 · 全文

机制：5,400 段中文对话、约 60K 轮、150 小时、113 位说话人，保留口语停顿、重复、自我修正与语气词，并标注时间及任务信息。支持语音、文字交替的分析；录音场景以安静室内为主，任务偏目标导向。

小夏实验： 用户语音提要求、文字改口、再用语音追问，检查对象和当前意图是否连续。用此类数据验证中文口语承接，再以自由聊天场景补足陪伴交流的评价。

阅读：数据收集、标注、跨模态协议及实验。

Codex 首轮实验

下面是建议开展的实验，不是已经跑出的项目结果。先每类用少量场景确认链路，再扩大为完整评测；三条原型使用相同任务、认知状态快照和工具权限。用于消融的配置匹配模型容量与计算预算；另做各路线原生最佳配置比较，保留各自长处。

实验	建议场景与对照	必须读出的结果
E1 连续自然聊天	24 个场景，每段 15-30 轮；分享、玩笑、观点、求助、纠正、转题混合。比较完整人设与相关状态激活、机械追问与价值导向策略	是否接住当前话题；有无自己的有用表达；重复、抢自述和过度追问；整段聊天偏好

实验	建议场景与对照	必须读出的结果
E2 相同文字、不同语气	40 组配对录音，如“行啊”“没事”“真厉害”，改变重音、停顿、疲惫感、真诚或反讽。比较转写、声学增强和原生音频输入	哪些线索改变理解；哪些仍然有歧义；回应是否恰当，而非情绪标签是否更激烈
E3 固定声线、灵活表达	32 句话 × 4 类语境；同意图改写，以及连续五句。比较参考音频、文本表达指令、内部条件控制	音色身份、表达适切性、自然度、句间连续性分开评；不要只看声纹相似度
E4 真实接话与打断	40 个脚本，Fast/Slow 两种节奏；包含犹豫停顿、短附和、真正插话、连续纠正。耳机和外放均测	误抢话、误停声、让话成功；回声影响；旧音频实际停止、改口后新回答及内容是否更新
E5 跨会话与跨模态记忆	12 个场景，每个 3 次会话；语音说明、文字修改、语音续聊。加入相关历史与已过时目标	相关经历自然生效；旧值不继续支配；来源与说话人正确；不过度翻旧账
E6 实际说出的内容	60 个中文及中英混合案例，涵盖姓名、数字、多音字、否定、选项和自我纠正	推理内容与实际音频分别核验；若有文字输出，再比较文字与说出内容的偏差
E7 流式预检索	12 个带后半句改口的请求，比较说完再检索与边听边预取	有意义回答等待、查询次数、修订取消、过时结果误用；预取仅针对读取

E1/E5 同时采用固定历史回放和真实连续对话。固定回放便于定位差异；实时对话让后续输入随模型真实回答调整。真人盲评以整段交流为主，模型裁判辅助找错误。场景、说话人与会话应分组划分训练/开发/测试，避免相似片段跨集合泄漏。

时间与内容如何测

每次会话记录同一条客户端时间轴：

1. 用户当前有效发言结束。
2. 系统判定可以接话。
3. 附和开始播放（如果有）。
4. 第一个有实质回应的音频开始播放。
5. 用户开始插话。
6. 旧音频实际停止。
7. 用户纠正说完。
8. 采用纠正后的新回答开始播放。

由此分别得到回答等待、附和时机、停旧声延迟和纠正后回答等待。服务端发出取消成功，与扬声器真正停声，是两个测点；“嗯、让我想想”也应与实质回答分开统计。再拆出端点、理解/推理、检索、首音生成、传输、排队和播放耗时，报告样本数、P50/P95、冷/热启动与长会话漂移。

内容核验针对真实音频；自动转写用于定位，数字、否定、名字等关键差异人工复核。声音自然度听原音，不能仅让裁判读转写。保留截断半字、残音、重播、丢帧、错附和和抢话的原始片段。

固定任务和资源后，结果属于该具体配置。记录 checkpoint、语言版本、量化、上下文、认知快照、网络、播放缓冲与设备；每次运行从干净测试状态开始，避免前一模型的实验记忆改变后一模型的输入。最终看内容、自然度、互动、身份、延迟和成本的取舍，不把所有指标揉成一个总分。

最小运行接口

先约定必要的信息，不急于规定进程或服务数量：

• 输入事件：时间戳、来源通道、识别假设及修订关系、可用声学表示。

• 生成请求：认知状态版本、当前交流意图、相关经历、待回答内容。

• 表达条件：声音身份、自然语言表达意图、必要的读音提示；韵律细节可由模型学习。

• 输出事件：生成片段、播放代次、已显示范围、已播放范围、取消和完成。

• 反馈事件：针对哪一段、哪一种问题--内容、时机、声音、记忆或发音。

互动控制负责时机，语言模型负责形成回应。模型内部可以联合完成这些能力；接口的作用是让实验可观测、输出能取消、状态能连续，而不是将聊天拆成固定模板流水线。

候选实现与训练投入

研究对象	现阶段可采用的材料	适合的角色
IndexTTS 系列	官方推理、声线与情绪分离接口；当前 v2.5 为后续工程版本，使用自定义模型许可	中文固定声音与表达控制的候选
F5-TTS	官方中英权重与推理；代码 MIT，公开权重 CC-BY-NC	非自回归生成与分句策略对照
LLaMA-Omni 2	官方双语 0.5B-32B 系列；代码 Apache-2.0，公开模型学术非商用	语义-语音耦合研究
Freeze-Omni	官方代码与模型材料；需要底座内部表示	冻结强语言底座的语音适配研究
Moshi / PersonaPlex 四轴 RL	论文作者发布的英语研究 checkpoint，卡片含非商用条件	互动策略与原生双工对照
GLM-4-Voice	中英 tokenizer、9B、decoder 与推理材料	文本知识进入语音通道的对照
NaturalSpeech 3 / PromptTTS 2 / OmniFlatten	分解表示、控制、训练与消融证据；开放程度各异	机制设计与后续训练依据

已通过 GitHub 读取 IndexTTS README、F5-TTS README、LLaMA-Omni 2 README。其余开放信息来自本轮作者页面与论文。正式模型版本、语言与许可在实际实验记录中固定，论文版本与后续工程版本分别标注。

你的 RTX 5070 Ti 16 GB、64 GB 内存可以作为一个具体部署测试点；本报告没有在这台设备跑模型，也不据参数量直接宣称整条路线能装下。先明确研究能力上限，再比较本机、远程推理及混合部署的实际成本与延迟。

反馈怎样形成持续改进

第一层是运行状态与记忆：一次纠正应立即改变当前理解和后续承接。

第二层是表达选择：积累同情境下的偏好，例如自然接话优于客服总结、有价值追问优于重复确认、克制表达优于夸张表演。可用于上下文组织、候选排序或小模型策略学习。

第三层是模型后训练：当错误模式稳定、样本可复现时，再对聊天策略、语音适配器或声学模型做定向 LoRA / 偏好优化。不同错误分别处理：发音错不必改整个人格，停声慢应先定位交互与播放链路，记忆选错则检查相关性与时间语义。

反馈要带场景和原因。用户嫌某次回复啰嗦，学到的是该情境下表达过长；不应被更新成“以后永远只说一句”。持续学习的目标是更细致地选择，而不是越来越僵硬。

交付顺序与 Codex 任务

第一步：建立共用实验与观测。 固定任务、认知快照、音频输入、客户端测点和人工盲评方法；现有实现成为一个可重复基准。

第二步：各做一条最小可运行原型。 A 测强内容与可控声音，B 测内部语义 / 声音连接，C 测持续互动。每条允许原生能力发挥，声线保持作为被测能力，不强迫全部接同一外部 TTS。

第三步：按问题做消融。 优先回答：声学线索是否提高理解？语义支撑是否改善说出内容？表达控制是否稳定声音？互动学习是否减少抢话与误停？记忆是否在需要时自然生效？

第四步：据证据确定主线与训练目标。 可能选择单一路线，也可能吸收 B 的语义接口与 C 的互动策略。保留能够支持结论的原始音频、事件时间轴和配对评审；在失败类别明确后安排训练投入。

可直接交给 Codex 的任务说明：

以本专项 28 篇论文为机制依据，开展小夏语音与聊天的架构实验。现有目录、引擎、模型与串行流程均可替换；论文提供假设与可复现实验，不规定必须复制其模块划分。

比较强语言模型加可控语音、语义与流式语音耦合、原生全双工三组原型。允许不同中间表示；分别标注是否保留副语言信息、如何组织语义、生成中是否持续监听、能否按用户意图让话。

每个实验写清论文来源、迁移假设、对照配置、客户端测点、质量标准与结果。研究自然聊天、固定声线表达、有效追问、口头纠正、跨模态记忆，以及真实外放情况下的接话和打断。

交付可复现实验清单、配置版本、场景与音频、事件日志、盲评结果和主线建议。结果应说明哪种配置在什么任务与资源下更好；把未达到的能力定位到理解、推理、表达、互动或运行链路，再决定下一步训练与实现。

阅读与版本说明

本报告核对了 28 篇正式会议出版信息，并阅读其方法、实验、关键消融或评测协议。研究卡给出实际阅读范围；工程方案、接口和实验规模为结合论文后提出的小夏设计建议。

NaturalSpeech 3、Freeze-Omni、LongMemEval、Stream RAG 和 IndexTTS2 的部分方法阅读采用链接所示作者全文版本；会场由正式出版页核实。Stream RAG 不混用预印本与正式版数值。Moshi 等模型名称可作为研究底座出现，但未把未核实会场的技术报告加入 28 篇正式论文数量。

与前序研究的衔接：小夏统一架构与实现路线。本专项扩展语音和聊天能力，允许实验结果反过来调整原来的整体方案。

小夏论文参考目录 v1.1

更新：2026-11-04。项目交付是不变量。论文、方法、算法、模型、参数、架构和实验设计均为可替换参考；Codex 可以改进、组合、替换或放弃，以实际交付效果和证据选择路线。

三份报告共 97 条引用，按论文身份去重为 91 项。语音聊天专项 28 篇正式会议论文的题名、会场与年份本轮重新核对；原始研究数据与阅读范围保留在对应研究稿中。

G01 · Cognitive Architectures for Language Agents

- 会场 / 版本：2023 / TMLR 2024
- 研究组：全项目
- 原文
- 阅读位置：§4 记忆、行动与决策；§5 案例；§6 讨论。

G02 · ReAct: Synergizing Reasoning and Acting in Language Models

- 会场 / 版本：2022 / ICLR 2023
- 研究组：全项目
- 原文
- 阅读位置：方法；§3 问答及事实核查；环境任务与错误分析。

G03 · Lost in the Middle: How Language Models Use Long Contexts

- 会场 / 版本：TACL 2024
- 研究组：全项目
- 原文
- 阅读位置：§2 实验设置与结果；§3 检索；§4-5 分析。

G04 · Large Language Models Cannot Self-Correct Reasoning Yet

- 会场 / 版本：2023 / ICLR 2024
- 研究组：全项目
- 原文
- 阅读位置：§3 内在纠错实验、提示变体及分析。

G05 · CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing

- 会场 / 版本：ICLR 2024
- 研究组：全项目
- 原文
- 阅读位置：§3 算法；§4 对照及无工具消融；附录 A 局限。

G06 · Establishing and Maintaining Long-Term Human-Computer Relationships

- 会场 / 版本：TOCHI 2005

- 研究组：全项目
- 原文
- 阅读位置：§4 关系沟通；§6 系统、随机分组、结果；§7 局限。

G07 · AI Companions Reduce Loneliness

- 会场 / 版本：2025 提前发表 / JCR 2026 卷期
- 研究组：全项目
- 原文
- 阅读位置：Study 3-5 方法和结果；General Discussion。

G08 · How AI and Human Behaviors Shape Psychosocial Effects of Extended Chatbot Use

- 会场 / 版本：2025 年 10 月 v2
- 研究组：全项目
- 原文
- 阅读位置：随机设计；主要结果；Discussion 与 Limitations。

G09 · Sycophantic AI decreases prosocial intentions and promotes dependence

- 会场 / 版本：Science 2026
- 研究组：全项目
- 原文
- 阅读位置：RQ2、RQ3 实验与局限。

G10 · Sycophantic AI makes human interaction feel more effortful and less satisfying over time

- 会场 / 版本：2026 年 6 月 v3 预印本
- 研究组：全项目
- 原文
- 阅读位置：Study 4 方法、结果、零结果和开放材料。

G11 · Generative Agents: Interactive Simulacra of Human Behavior

- 会场 / 版本：UIST 2023
- 研究组：全项目
- 原文
- 阅读位置：§4；§6.4-6.5；§7-8。

G12 · MemoryBank: Enhancing Large Language Models with Long-Term Memory

- 会场 / 版本：2023 / AAAI 2024
- 研究组：全项目

- 原文
- 阅读位置：§2.1-2.3；§4.1-4.2、Table 2。

G13 · MemGPT: Towards LLMs as Operating Systems

- 会场 / 版本：2023 / 阅读 2024 v2
- 研究组：全项目
- 原文
- 阅读位置：§2.1-2.4；§3.1-3.2。

G14 · A-Mem: Agentic Memory for LLM Agents

- 会场 / 版本：2025 v4
- 研究组：全项目
- 原文
- 阅读位置：§3.1-3.4；§4.1-4.6；附录 B.4。

G15 · Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory

- 会场 / 版本：2025 v1
- 研究组：全项目
- 原文
- 阅读位置：§2.1-2.2；§3；§4.3-4.5；附录算法。

G16 / P06 · LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory

- 会场 / 版本：ICLR 2025
- 研究组：全项目、语音与聊天
- 原文
- 出版 / 记录页
- 阅读位置：§3-5；Tables 3-4；相关附录。

G17 · Evaluating Very Long-Term Conversational Memory of LLM Agents

- 会场 / 版本：LoCoMo / ACL 2024，阅读 v1
- 研究组：全项目
- 原文
- 阅读位置：§3-6；§8 局限。

G18 / P07 · Locomo-Plus: Beyond-Factual Cognitive Memory Evaluation Framework for LLM Agents

- 会场 / 版本：ACL 2026 主会

- 研究组：全项目、语音与聊天
- 原文
- 出版 / 记录页
- 阅读位置：§3-6；Table 1；Limitations；附录 B。

G19 · RoleLLM: Benchmarking, Eliciting, and Enhancing Role-Playing Abilities of Large Language Models

- 会场 / 版本：2023 / ACL Findings 2024
- 研究组：全项目
- 原文
- 阅读位置：§3-5；Tables 1、6、7。

G20 · Character-LLM: A Trainable Agent for Role-Playing

- 会场 / 版本：EMNLP 2023
- 研究组：全项目
- 原文
- 阅读位置：§3 经历重建与训练；§4；局限。

G21 · InCharacter: Evaluating Personality Fidelity in Role-Playing Agents through Psychological Interviews

- 会场 / 版本：ACL 2024
- 研究组：全项目
- 原文
- 阅读位置：§3-5；人工验证与局限。

G22 · PersonaGym: Evaluating Persona Agents and LLMs

- 会场 / 版本：EMNLP Findings 2025 / v5
- 研究组：全项目
- 原文
- 阅读位置：§2-5；评分示例和偏差检查。

G23 / P04 · EmoCharacter: Evaluating the Emotional Fidelity of Role-Playing Agents in Dialogues

- 会场 / 版本：NAACL 2025 主会
- 研究组：全项目、语音与聊天
- 原文
- 出版 / 记录页
- 阅读位置：§3-5；§7 限制。

G24 / P08 · Can You Put it All Together: Evaluating Conversational Agents' Ability to Blend Skills

- 会场 / 版本：ACL 2020 主会，经典基础
- 研究组：全项目、语音与聊天
- 原文
- 出版 / 记录页
- 阅读位置：§3 数据与训练；§4 实验和人评。

G25 · Recipes for Building an Open-Domain Chatbot

- 会场 / 版本：2020 / EACL 2021
- 研究组：全项目
- 原文
- 阅读位置：生成策略；ACUTE-Eval；§10.5 失败。

G26 · Towards Understanding Sycophancy in Language Models

- 会场 / 版本：ICLR 2024
- 研究组：全项目
- 原文
- 阅读位置：§3 四类任务；§4 偏好分析与优化；§5-6。

G27 · Principles of Mixed-Initiative User Interfaces

- 会场 / 版本：CHI 1999
- 研究组：全项目
- 原文
- 阅读位置：设计原则；效用与时机；长期学习。

G28 · Proactive Agent: Shifting LLM Agents from Reactive Responses to Active Assistance

- 会场 / 版本：ICLR 2025
- 研究组：全项目
- 原文
- 阅读位置：§3-4；附录 C.5；局限。

G29 · After Talking with 1,000 Personas: Learning Preference-Aligned Proactive Assistants from Large-Scale Simulated Persona Interactions

- 会场 / 版本：2026 年 8 月 v3
- 研究组：全项目
- 原文
- 阅读位置：§5-10；用户研究和局限。

G30 · ProMISe: A Proactive Multi-turn Dialogue Dataset for Information-seeking Intent Resolution

- 会场 / 版本：EACL Findings 2024
- 研究组：全项目
- 原文
- 阅读位置：§3-5；§7；附录 A。

G31 · Personalized Topic Selection Model for Topic-Grounded Dialogue

- 会场 / 版本：PETD / ACL Findings 2024
- 研究组：全项目
- 原文
- 阅读位置：§3；§4.1-4.7；局限。

G32 · WebGPT: Browser-assisted question-answering with human feedback

- 会场 / 版本：2021 / 阅读 2022 v3
- 研究组：全项目
- 原文
- 阅读位置：§2-4；§6.1-6.3。

G33 · FunAudioLLM: Voice Understanding and Generation Foundation Models for Natural Interaction Between Humans and LLMs

- 会场 / 版本：2024
- 研究组：全项目
- 原文
- 阅读位置：§2.2；§4.1-4.3；§5-6。

G34 · CosyVoice 3: Towards In-the-wild Speech Generation via Scaling-up and Post-training

- 会场 / 版本：2025 / v2
- 研究组：全项目
- 原文
- 阅读位置：tokenizer、后训练方法；实验及控制机制。

G35 / P13 · IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech

- 会场 / 版本：AAAI 2026 主会
- 研究组：全项目、语音与聊天
- 原文

- 出版 / 记录页
- 原文
- 阅读位置：情绪 / 音色解耦、时长控制；实验。

G36 · CoCoEmo: Composable and Controllable Human-Like Emotional TTS via Activation Steering

- 会场 / 版本：2026 年 2 月预印本
- 研究组：全项目
- 原文
- 阅读位置：§2 交叉条件；steering 方法；Tables 2-3；附录。

G37 · Fish Audio S2 Technical Report

- 会场 / 版本：2026 年 3 月
- 研究组：全项目
- 原文
- 阅读位置：§2.2；§3.2；§4.2-4.3；§5 与附录。

G38 · Seed-VC: Zero-shot Voice Conversion with Diffusion Transformers

- 会场 / 版本：2024 / 阅读 v1
- 研究组：全项目
- 原文
- 阅读位置：§3.3-3.5；§4.1；§4.3.2。

G39 · TurnGPT: a Transformer-based Language Model for Predicting Turn-taking in Spoken Dialog

- 会场 / 版本：EMNLP Findings 2020
- 研究组：全项目
- 原文
- 阅读位置：§3-4；§6.2-6.3。

G40 · Real-time and Continuous Turn-taking Prediction Using Voice Activity Projection

- 会场 / 版本：IWSDS 2024
- 研究组：全项目
- 原文
- 阅读位置：§2 模型；§3 性能。

G41 / P20 · Freeze-Omni: A Smart and Low Latency Speech-to-speech Dialogue Model with Frozen LLM

- 会场 / 版本：ICML 2025

- 研究组：全项目、语音与聊天
- 原文
- 出版 / 记录页
- 原文
- 阅读位置：§2；§3.4-3.5；§4。

G42 · Moshi: a speech-text foundation model for real-time dialogue

- 会场 / 版本：2024 v2
- 研究组：全项目
- 原文
- 阅读位置：§3.3-3.4；§5.2-5.3、5.8；§6.3。

G43 · SoulX-Singer: Towards High-Quality Zero-Shot Singing Voice Synthesis

- 会场 / 版本：2026 年 2 月
- 研究组：全项目
- 原文
- 阅读位置：§2.1-2.2；§3.1-3.3。

G44 · OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments

- 会场 / 版本：2024 v2
- 研究组：全项目
- 原文
- 阅读位置：§2-3；Table 5；§5。

G45 · Windows Agent Arena: Evaluating Multi-Modal OS Agents at Scale

- 会场 / 版本：2024 / ICML 2025
- 研究组：全项目
- 原文
- 阅读位置：§3-5；正式会议页。

G46 · UI-TARS: Pioneering Automated GUI Interaction with Native Agents

- 会场 / 版本：2025 v1
- 研究组：全项目
- 原文
- 阅读位置：§4.3-4.6；§5.4；Table 9。

G47 · Agent S2: A Compositional Generalist-Specialist Framework for Computer Use Agents

- 会场 / 版本：2025 v1
- 研究组：全项目
- 原文
- 阅读位置：§3-4；Tables 1-3。

G48 · InjecAgent: Benchmarking Indirect Prompt Injections in Tool-Integrated Large Language Model Agents

- 会场 / 版本：ACL Findings 2024
- 研究组：全项目
- 原文
- 阅读位置：§2-3；Table 3；§8。

G49 · AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents

- 会场 / 版本：2024 v3
- 研究组：全项目
- 原文
- 阅读位置：§3-4；附录 C。

G50 · Defeating Prompt Injections by Design

- 会场 / 版本：CaMeL / 2025 v1
- 研究组：全项目
- 原文
- 阅读位置：§3-6；§8；附录 B。

G51 · Evolving Agent Interfaces

- 会场 / 版本：Agent S4 / 2026 年 10 月预印本
- 研究组：全项目
- 原文
- 阅读位置：§3-7；Tables 1-4；附录 A.2。

G52 · τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains

- 会场 / 版本：2024 / ICLR 2025
- 研究组：全项目
- 原文
- 阅读位置：§3-6；失败分析。

G53 · LifelongAgentBench: Evaluating LLM Agents as Lifelong Learners

- 会场 / 版本：2025 v3
- 研究组：全项目
- 原文
- 阅读位置：§3-7。

C01 · An Integrated Theory of the Mind

- 会场 / 版本：2004，链接为作者早期稿
- 研究组：认知机制
- 原文
- 阅读位置：陈述记忆、激活方程、fan effect、规则效用

C02 · LIDA A Systems-level Architecture for Cognition Emotion and Learning

- 会场 / 版本：2014
- 研究组：认知机制
- 原文
- 阅读位置：III、VI、VII、VIII、X

C03 · EMA A process model of appraisal dynamics

- 会场 / 版本：2009
- 研究组：认知机制
- 原文
- 阅读位置：2.3.2-2.3.5

C04 · A Standard Model of the Mind

- 会场 / 版本：2017
- 研究组：认知机制
- 原文
- 阅读位置：Structure and Processing、Memory and Content、Learning

C05 · Integrating language model embeddings into the ACT-R cognitive modeling framework

- 会场 / 版本：2026
- 研究组：认知机制
- 原文
- 阅读位置：2.2-2.3 与结果部分

C06 · From RAG to Memory: Non-Parametric Continual Learning for Large Language Models

- 会场 / 版本：HippoRAG 2，ICML 2025
- 研究组：认知机制
- 原文
- 阅读位置：3-6、附录 G、表 4

C07 · Zep A Temporal Knowledge Graph Architecture for Agent Memory

- 会场 / 版本：2025
- 研究组：认知机制
- 原文
- 阅读位置：2-4

C08 · Synapse Empowering LLM Agents with Episodic-Semantic Memory via Spreading Activation

- 会场 / 版本：2026 预印本
- 研究组：认知机制
- 原文
- 阅读位置：3.1-3.4、4.3

C09 · Why There Are Complementary Learning Systems in the Hippocampus and Neocortex

- 会场 / 版本：1995
- 研究组：认知机制
- 原文
- 阅读位置：快慢学习、交错训练、巩固论证

C10 · MemRL Self-Evolving Agents via Runtime Reinforcement Learning on Episodic Memory

- 会场 / 版本：2026 预印本
- 研究组：认知机制
- 原文
- 阅读位置：3-5、附录 A、G.1-G.2

C11 · The Neuro-Symbolic Concept Learner: Interpreting Scenes, Words, and Sentences from Natural Supervision

- 会场 / 版本：ICLR 2019
- 研究组：认知机制

- 原文
- 阅读位置：3.1-3.2、4.1-4.2

C12 · Logical Neural Networks

- 会场 / 版本：2020
- 研究组：认知机制
- 原文
- 阅读位置：3-4、6-7

C13 · Overcoming catastrophic forgetting in neural networks

- 会场 / 版本：PNAS 2017
- 研究组：认知机制
- 原文
- 阅读位置：参数重要性方法、公式 3、顺序任务实验

C14 · Learning to Learn without Forgetting by Maximizing Transfer and Minimizing Interference

- 会场 / 版本：ICLR 2019
- 研究组：认知机制
- 原文
- 阅读位置：2-3、Algorithm 1、实验

C15 · On Tiny Episodic Memories in Continual Learning

- 会场 / 版本：2019
- 研究组：认知机制
- 原文
- 阅读位置：3-5

C16 · Neuromodulated Spike-Timing-Dependent Plasticity and Theory of Three-Factor Learning Rules

- 会场 / 版本：2016 理论综述
- 研究组：认知机制
- 原文
- 阅读位置：4-5，尤其 eligibility trace 与延迟反馈

P01 · Controlling and Assessing Appropriate Persona Use in LLM-based Dialogue Generation

- 会场 / 版本：EMNLP 2026 主会
- 研究组：语音与聊天

- 出版 / 记录页
- 原文
- 阅读位置：§2-5，表 2/3/6/7，附录 B/C。

P02 · Don’t Guess, Ask Wisely: Benchmarking and Training Proactive Elicitation in Open-Domain LLM Conversations

- 会场 / 版本：EMNLP 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.3-5.2，表 2/3及消融。

P03 · SODA: Million-scale Dialogue Distillation with Social Commonsense Contextualization

- 会场 / 版本：EMNLP 2023 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§2-5，表 5-7及人评设置。

P05 · AMULET: Putting Complex Multi-Turn Conversations on the Stand with LLM Juries

- 会场 / 版本：EMNLP 2025 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§2-4，表 2-4。

P09 · StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models

- 会场 / 版本：NeurIPS 2023 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.2、§4、§5.2-5.3。

P10 · NaturalSpeech 3: Zero-Shot Speech Synthesis with Factorized Codec and Diffusion Models

- 会场 / 版本：ICML 2024

- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3、§4.1/4.3，附录 A.5-A.6。

P11 · PromptTTS 2: Describing and Generating Voices with Text Prompt

- 会场 / 版本：ICLR 2024
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.1-3.3、§4、§5.1-5.3。

P12 · EmoKnob: Enhance Voice Cloning with Fine-Grained Emotion Control

- 会场 / 版本：EMNLP 2024 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3-5。

P14 · F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching

- 会场 / 版本：ACL 2025 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.1-3.2、§5.1、表 1及采样分析。

P15 · VoiceCraft: Zero-Shot Speech Editing and Text-to-Speech in the Wild

- 会场 / 版本：ACL 2024 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3、§5.1/5.3/5.4。

P16 · Advancing Zero-shot Text-to-Speech Intelligibility across Diverse Domains via Preference Alignment

- 会场 / 版本：ACL 2025 主会
- 研究组：语音与聊天
- 出版 / 记录页

- 原文
- 阅读位置：§3-5，附录 D/F。

P17 · Multi-Faceted Interactivity Alignment in Full-Duplex Speech Models

- 会场 / 版本：EMNLP 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.2-5。

P18 · Full-Duplex-Bench-v2: A Multi-Turn Evaluation Framework for Duplex Dialogue Systems with an Automated Examiner

- 会场 / 版本：ACL 2026 主会短文
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§2.1-2.4、§3及附录。

P19 · Talking Turns: Benchmarking Audio Foundation Models on Turn-Taking Dynamics

- 会场 / 版本：ICLR 2025
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§3.2、§4.1-4.8、§7及用户研究。

P21 · LLaMA-Omni 2: LLM-based Real-time Spoken Chatbot with Autoregressive Streaming Speech Synthesis

- 会场 / 版本：ACL 2025 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§2-5，重点消融表。

P22 · OmniFlatten: An End-to-end GPT Model for Seamless Voice Conversation

- 会场 / 版本：ACL 2025 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文

- 阅读位置：§3-4，表 3/4。

P23 · Scaling Speech-Text Pre-training with Synthetic Interleaved Data

- 会场 / 版本：ICLR 2025
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：§2.1-2.4、§3.1-3.3。

P24 · Stream RAG: Instant and Accurate Spoken Dialogue Systems with Streaming Tool Usage

- 会场 / 版本：ICML 2026
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：作者版 §3-5；正式会场由 PMLR 核实。

P25 · What Do Prosody and Text Convey? Characterizing How Meaningful Information is Distributed Across Multiple Channels

- 会场 / 版本：ACL 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：方法、通道比较与实验讨论。

P26 · Audio MultiChallenge: A Multi-Turn Evaluation of Spoken Dialogue Systems on Natural Human Interaction

- 会场 / 版本：ACL 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：数据构造、四类任务、评测协议及结果。

P27 · S2S-Arena: Evaluating Paralinguistic Instruction Following in Speech-to-Speech Models

- 会场 / 版本：ACL 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页

- 原文
- 阅读位置：任务定义、样本构造、比赛与裁判验证。

P28 · RealTalk-CN: A Realistic Chinese Speech Task-Oriented Dialogue Benchmark with Cross-Modal Analysis

- 会场 / 版本：ACL 2026 主会
- 研究组：语音与聊天
- 出版 / 记录页
- 原文
- 阅读位置：数据收集、标注、跨模态协议及实验。