小夏 · 演唱与基座

专项研究 / 七篇会议论文 / 模型与运行时 / 交付合同依据

更新：2026-11-04（北京时间）。供 Owner 裁决与 Codex 后续实现使用。

> 项目交付是不变量；论文、模型、算法、内部表示、框架与部署拓扑可改。采用新机制是为了改善实际体验；有更好证据时可以组合、替换或放弃旧方案。完整演唱和已约定能力继续保留，新增创作与精细编辑列为候选，采纳后再进入交付验收。

一页结论

唱歌与戏曲需要独立专项，基座采用"成熟模型与工具 + 小夏自有的连续认知 / 交付内核"。

统一的是小夏的身份、经历、目标、声音锚点与作品；底层既可以由专业模型协作，也可以逐步合并成统一声音模型。这种统一不要求每种模型共用同一组参数或相同 speaker embedding。

建议的起步组合：

层	推荐起点	自己掌握什么
语言理解与推理	当前已接入的强云端 LLM；模型可比较替换	工作集、目标、记忆更新、工具与结果语义
认知与状态	自有 Python 领域模块；复用现有状态 / 持久化能力	共同经历、关系、关注、反馈与有效版本
渠道	AstrBot 继续承担 QQ / 微信接入	跨渠道身份、作品归属、消息能力和投递结果
连续语音	LiveKit Agents 候选；Pipecat 为轻量替代	实际播放、话轮、打断、恢复和唱后回聊
歌唱与戏曲	SoulX-SVC / SVS、Seed-VC、DiffSinger / OpenUtau 按任务比较	作品版本、词谱与表演计划、声音身份、完整作品验收
新作品创作	ACE-Step 1.5 作为首个比较候选	创作意图、结构、修订与成品；本项为增强探索线
任务运行	单机 Python + SQLite / 现有 SQLAlchemy；GPU 依赖隔离	作业、阶段工件、取消、恢复、资源和真实交付
后续编排	复杂认知流程可选 LangGraph；跨机长任务可选 Temporal	业务状态不由框架的私有 checkpoint 代管

这是推荐组合，不是必须全装的依赖清单。单机桌宠若 Pipecat 更省事，或统一声音模型在听审和资源上胜出，直接依据证据改选。

为什么演唱需要独立能力线

普通说话由语言语义主导韵律，歌唱要满足旋律与节奏，戏曲还要处理剧种、字音、行当、板式与表达性变化。需要分别控制和验收三个问题：

1. 谁在唱：小夏声音身份是否贯穿说话、歌唱、念白与不同音域。

2. 唱什么：作品 / 版本、歌词、段落、旋律、节奏与伴奏是否正确完整。

3. 怎样唱：轻重、气口、滑音、颤音、拖腔、角色和剧种特点是否成立。

论文给出的有用机制是时长与风格联合预测、细粒度音素 / 音高条件、局部错误建模和配对数据。项目将这些机制作为候选，不要求同时复现每篇网络结构。

“自己写基座”该写到哪里

自有是掌握数据与语义，不是每层都从零制造。

建议自己写 / 整理：经历与认知更新、跨渠道人物映射、声音与作品版本、交付状态、可恢复作业、资源调度、评价与反馈归属。已有 shared_core、投递策略与本地语音接口继续复用，按真实变更影响逐步收敛。

建议复用：预训练 LLM、ASR、TTS、SVC / SVS、声码器、人声分离、F0 提取、歌词 / 谱对齐、音乐编辑器、数据库、音频编解码和实时媒体协议。专用缺口先做数据与适配实验；目标剧种 / 音域持续不达标时，才投入专用适配器或声学模型训练。

认知成长可以发生在三处：持久经历与关联更新；按反馈调整情境策略；在合格数据上训练专用参数。三种路线可独立试验，不要求每次相处都更新大模型权重，也不固定永远不训练。

当前仓库与这次工作的关系

已读默认分支快照为 8c63aff5a18fcccd624ad0f29ee70f303e15975b。GOAL 原文 记录 Fish S2 + Seed-VC 候选已切换，按用户要求暂停继续打磨。此次交付仅补研究、架构图和合同，没有实施新模型或修改仓库。

公开配置提供 chatgpt-companion 别名及多种模型候选，实际主聊天模型由运行配置选择。因此推荐强云端主推理接口，而不把公开列表首项误写成当前运行型号。

本轮证据包含：7 篇正式演唱 / 戏曲会议论文的方法与实验阅读；专业模型技术报告；官方代码、模型卡与运行文档。另补统一声音方向。此前的全项目、认知、语音聊天研究及 91 项文献母册继续保留。论文分数是原实验结果，本机候选尚需按合同实测。

怎样从研究进入下一轮工作

首个优先纵切建议是：用户点一首完整作品 → 可查询制作进度 → 小夏声音完成演唱 → 真实可播 / 可收 → 重启后作品与状态仍在 → 继续聊天。

把声学上限与自主链路分开测：给准确词谱时唱不好，重点查渲染 / 数据；给准确词谱能唱好而点歌失败，重点查选版、准备、对齐和编排。这比不断换一个“更大模型”更容易找到真正的瓶颈。

精细局部编辑、自动创作、实时对唱是有价值的增强候选。先保留试验空间，不让新功能悄悄变成原完整演唱的额外交付门槛。

小夏 v1.2：唱歌与戏曲专项研究补充

日期：2026-11-04。正式会议论文的方法、实验与项目取舍。

结论

需要独立专项，但应作为小夏统一声音表达系统中的能力域，而不是再造一个人格或另起一套聊天产品。 聊天、朗读、哼唱、歌曲、戏曲共享小夏的声音身份、交互会话与长期偏好；各自可采用最合适的模型。长期可试验统一说唱模型，近期也允许专业渲染器协作。

原专项交付是完整指定作品与戏曲，以及贯穿说话、歌唱和念白的声音身份。给词给谱、精细改字改腔和全曲原创作为可探索增强项，Owner 采纳后进入相应验收；现阶段可按纠正重做完整作品。戏曲交付需声明覆盖的剧种、方言和行当，并完成相应完整唱段。模型、方法、控制字段和下列论文均为可替换候选；替换以目标旅程、听感与实测结果裁决。

能力与输入分工

能力	核心输入	适用用途	要独立验证的部分
歌声转换 SVC	已有演唱 + 目标声音参考	快速保留原表演的音高、节奏与唱法，换成小夏音色	源歌手音色残留；转音、辅音和高音损伤
可控演唱 SVS	歌词 + 曲谱/旋律 + 表演条件	指定曲目、改词、清唱、逐句改腔	音素时长、咬字、音准、技巧与身份稳定
全曲生成	创作意图/歌词/风格，可带参考	新歌、伴奏、完整编曲	整曲结构、歌词覆盖、主副歌延续、声部混音
戏曲表演	剧种/方言/行当 + 唱词/曲牌或板式 + 表演参考	完整唱段、唱念衔接、角色化表演	方言字音、字头字腹字尾、一字多音、行腔与伴奏落点

这四项是交付能力的区分，不要求四个大模型，也不要求所有模型一次性安装。原始演唱复制适合 SVC，自主决定怎么唱需要 SVS/生成规划；整曲创作和戏曲角色表达不应被一个短音频示例替代。

七篇原论文：已读取的方法和实验

说明：下列数值均为各论文内部实验，不能把不同数据、测试句和听众下的 MOS 直接排成跨论文排行榜。本轮读取了各篇下列方法、数据、主要实验与消融章节；未运行作者代码，未听评作者音频，未把摘要当作已读全文。

S01 - FT-GAN: Fine-Grained Tune Modeling for Chinese Opera Synthesis

• 会场：AAAI 2024，38(17)，19697-19705；正式主会论文。

• 官方论文；PDF；作者代码。

• 已读：Dataset Construction；Method（Conditioner、Mel Predictor、Discriminator、Losses、Speech Pre-Training）；Experiments；Extensive Experiments；Tables 1-4。

• 机制：歌仔戏数据显式标注元音变形及一字多音；音素与音高分开编码后用 FiLM 融合，Conformer 建模长短依赖，多时长/频带判别器细化频谱。

• 证据：5 位演员、4.54h 闽南语歌仔戏；加入3.77h同方言语音预训练。歌仔戏自然度 MOS 4.18，对照 VISinger2 3.90；去掉元音变形标注后发音 CMOS 为 −0.43（Table 3，w/o Vowel Morphing 行、Pro 列，相对完整模型）。京剧扩展因数据少改用真实 F0 输入，不能将该结果当作纯曲谱驱动能力。

• 小夏试验：先比较“普通拼音标注”与“按实唱拆音素/转腔标注”，再决定是否更换声学骨干；观察改标注对字音和长尾腔的收益。

S02 - Improving Chinese Pop Song and Hokkien Gezi Opera Singing Voice Synthesis by Enhancing Local Modeling

• 会场：EMNLP 2023 main，3302-3312；正式主会论文。

• 官方论文；PDF；作者代码。

• 已读：§2.1-2.3 方法；§3 实验；§4.1-4.4 结果/消融/案例；Limitations；Tables 1-4。

• 机制：音素邻域局部注意力与全局注意力门控融合；对难合成音素区域提高重建损失权重，解决咬字、呼吸与局部噪声。

• 证据：5.89h普通话流行歌曲及4.5h闽南语歌仔戏；10名听众。歌仔戏基线 MOS 3.46±0.15，改进后3.61±0.12；接入 DiffSinger 的同数据结果3.82→3.86，收益较小。

• 小夏试验：把“整体还行但某个字破音/尾腔抖动”作为定位目标，比较局部修复、损失重加权与整体换模型，保留字级错误片段。这里的局部建模是候选修理方法，不应强制加入每个模型。

S03 - Peking Opera Synthesis via Duration Informed Attention Network

• 会场：Interspeech 2020，1226-1230；语音领域正式主会论文。

• 官方记录；作者预印本全文。

• 已读：§2.1-2.3 方法；§3.1-3.3.2 数据、时长与合成实验；§4结论；Table 1。

• 机制：预测音素时长分布，在音符总时长约束下求解分配；从实唱转写伪谱训练，以容纳转音与颤音。重点是谱面音符与实际演唱不完全相同。

• 证据：2h标注京剧、606唱句；64唱句测试。10ms帧下，BiLSTM-MDN加约束的平均时长误差8.91帧，同网络启发式分配17.15帧；纯曲谱合成 MOS 3.34。

• 小夏试验：单字长腔、多音素同等重要的唱句，对比“拉长主元音”与学习式分配；验收音节内部节奏和戏味，而非只检查最终音频时长一致。

S04 - Towards Chinese Yue Opera Singing Voice Synthesis: A Benchmark with Dataset, Data Augmentation and Baseline Model

• 会场：Interspeech 2026，1596-1600，DOI 10.21437/Interspeech.2026-131；官方记录和 PDF 已核实。

• 官方记录；PDF。

• 已读：§2 YOAT 数据/三类增广；§3声学模型；§4实验设置；§5.1-5.3结果；Tables 1-3。

• 机制：吴语越剧发音词典、人工音素对齐、多音高尾腔；给定对齐时长与音高，条件流匹配生成频谱。念白补字音，跨歌仔戏数据补音高/节奏覆盖。

• 证据：单演员小生行当，1.35h/565片段，22测试句；10步模型自然度3.92±0.07，3090上24.678M参数、1296MB、RTF0.0364。加4.5h歌仔戏后F0 RMSE 0.2133→0.1834，自然度3.92→4.01。

• 小夏试验：分开测“给定准确时长/音高”的声学上限和“自动从词谱规划”的产品链路。该模型未预测时长，单剧种小生数据不覆盖所有戏曲行当。

S05 - TCSinger: Zero-Shot Singing Voice Synthesis with Style Transfer and Multi-Level Style Control

• 会场：EMNLP 2024 main，1960-1975；正式主会论文。

• 官方论文；PDF；作者项目。

• 已读：§3.1-3.5方法；§4.1-4.3实验/消融；§6局限；附录A.3-A.7、B和C.1；Tables 1-5、7。

• 机制：音色、内容、风格分离；聚类VQ提取音素级风格；Style & Duration LM联合预测风格和时长；扩散预测音高，风格自适应解码器合成。

• 证据：组合 GTSinger 中英子集、M4Singer、OpenSinger、AISHELL-3 与 PopBuTFy，留出40歌手；零样本风格迁移质量/相似度 MOS 4.12/4.28，对照StyleSinger 3.94/4.01。去掉联合时长模型质量/相似度CMOS下降0.12/0.22。训练时长合计在原文中不一致，故不采用合计数（见下方复核记录）。

• 小夏试验：同一个声音参考，换内容与唱法，分别盲评"仍然是小夏"及"表达变化生效"。论文文字控制实际为类别嵌入（两种情绪/两种唱法/六种技巧），自由中文指令需另接解释层。

S06 - TechSinger: Technique Controllable Multilingual Singing Voice Synthesis via Flow Matching

• 会场：AAAI 2025，39(22)，23978-23986；官方 Proceedings 记录为 AAAI-25 Technical Track on Natural Language Processing I，DOI 10.1609/aaai.v39i22.34571。

• 官方论文；作者全文；作者代码。

• 已读：TechSinger 全部方法小节；Experiments（设置、Main Results、Ablation Study）；Tables 1-5。

• 机制：自然语言→音素级演唱技巧；技巧检测器补标训练数据；流匹配预测F0与细化频谱；音高、时长、技巧共同参与生成。

• 证据：五语言GTSinger子集、自录30h中文及M4Singer；歌唱合成测试804片段。文字提示策略质量/可控性 MOS3.85/4.04，随机策略3.78/3.76。音频→音素级技巧检测器的 F1 为0.770（Table 4，whole 行，六种非滑音技巧；滑音按规则判定）；文字提示→技巧预测器另测，FLAN-T5-Large 的 F1 为0.818（Table 3）。

• 小夏试验：让用户说"这一句轻一点、尾字带颤音"，保存生成的局部技巧计划，做同词同旋律对照；纠正应落到时间段和技巧，避免把用户一次偏好变成永久全局音色变化。

S07 - GTSinger: A Global Multi-Technique Singing Corpus with Realistic Music Scores for All Singing Tasks

• 会场：NeurIPS 2024 Datasets and Benchmarks Track；正式数据集与基准论文。

• 官方论文；PDF。

• 已读：§3.1-3.6数据构建与许可；§4.1-4.4四类基准；§5局限；Tables 2-6。

• 机制：同歌手同歌词的自然唱、技巧唱及朗读配对；音素边界、技巧、真实乐谱同步标注。语音-唱歌身份连续与局部技巧控制有明确监督基础。

• 证据：20歌手、9语言、80.59h歌唱及16.16h配对朗读；六种技巧。基准留100首歌，技巧控制StyleSinger MOS-C4.15，对照DiffSinger3.83。

• 小夏试验：建立小而干净的说/唱/技巧对照锚点，按整曲/来源录音分割训练与测试；该数据以流行/美声为主，需另有剧种资料。数据许可CC BY-NC-SA 4.0，作为研究输入与随产品分发应分开核对。

从论文转为小夏实现：建议而非冻结架构

下列实验、接口和增强功能都是候选。局部编辑 / 全曲原创不自动成为原完整演唱目标的新增完成条件；能力范围由合同 v1.2 统领。

1. 固定能力目标，接口可演进

可以先提出一个版本化的表演请求，而不是把任何论文内部张量暴露给聊天层。最小信息包括：作品/歌词来源、目标内容、旋律来源、声音身份参考、语言与剧种条件、局部表达意图、是否需要伴奏、可用设备/延迟预算。输出包括可播放音频及与歌词/段落对应的时间线；具体字段由首个可运行纵切修订。

这里分开的是业务含义：

• 作品层：唱哪一首、哪一段、歌词与版本。

• 表演层：谁唱、怎样唱、何处换气、哪句改动、伴奏如何进入。

• 渲染层：选用什么声学模型、采样配置、声码器与混音器。

• 交互层：用户听到了哪里、何时打断、怎样修改和接着唱。

可以合并服务或共享一个模型；避免把一个emotion=opera字符串当作整个戏曲任务的数据表达。

2. 基座不是“全自己写”与“套现成模型”二选一

优先复用成熟预训练声学/语言模型及音频运行库；由项目掌握表演请求、身份锚点、内容和时间线、交互取消、任务状态、评测样本与反馈归属。缺口若在方言、念白或行腔，先验证数据适配/微调/小型专用模块的收益。只有既有模型在明确目标上持续失败，才把新声学骨干或训练路线列为研发任务。

统一说唱基座值得实验，但选择标准是“说话像她、唱歌像她、切换不断、设备撑得住”，不是模型结构是否漂亮统一。专业戏曲声学模块可以是共享模型的适配器，也可以是独立后端。作品与身份状态不能绑定某一份模型私有格式。

3. 两条试验轨并行，避免拿模型上限冒充产品闭环

试验轨	控制条件	主要定位
声学上限轨	人工正确的歌词、音高、时长与声音参考	模型能否唱好、发音和音色是否可达
自主表演轨	用户自然语言/曲名/上传曲谱或哼唱	系统能否正确解释、规划、合成、混音、播放并接受修改

有精细输入时效果好，而自主链路效果差，应优先修词谱、时长、技巧计划或对齐；两条轨都差，再优先修数据、声学模型或声码器。

4. 建议任务拆分

1. 声音身份与表演基线：同一身份完成聊天、朗读、短唱、长音和角色化念白；留音频锚点及盲测对照。

2. 可控演唱纵切：用户指定歌词/旋律→完整作品或唱段→可回听；采纳增强编辑后再支持改词、转调或局部表达修改，并记录改动范围。

3. 戏曲纵切：选定首批剧种/方言/行当，建立字音与行腔材料，完成唱、念与衔接；扩展剧种由用户价值和数据可得性排序。

4. 完整作品与交互：长段落一致、伴奏对齐、段间衔接；演唱中被打断能及时止声，再恢复时不重复已听内容。

5. 反馈学习：“错字音”“调高了”“这里拖长”“不像小夏”“这句唱法我喜欢”分别进入不同改进路径；保留原作品、原表演和改进版本。

6. 部署与生命周期：5070 Ti 16GB上实测常驻/按需装载/离线渲染三策略；同时考察聊天存活、显存峰值、冷启动、任务中断恢复和作品导出。

各阶段以可使用旅程验收，不以复现论文分数或堆满模块验收。性能阈值随目标设备基线和用户体验共同确定，论文设备数据仅用于安排试验优先级。

5. 完成交付应有的证据

交付关系	证据要求
内容正确	歌词/念白漏字、重复、错读可定位；方言由适合的标注或听评校验
旋律与表达	固定旋律下改技巧有效；转音/颤音依表演目标评价，不能一概作为音准误差扣分
声音连续	同一人不同任务/音区/情绪的盲听身份相似度，辅以声纹指标
长作品完成	完整歌曲或完整唱段回听；段落结构、呼吸、声线、响度、伴奏对齐持续稳定
可交互	打断→停止实际播放；采纳精细编辑后定位修改→局部重渲染；重启→作品、任务和反馈状态可恢复
可维护替换	换声学模型仍能消费原作品与表演请求，保留原始资料和结果比较
不靠挑样本	保存全部测试输出、失败片段、配置、模型版本、数据切分；同条件比较后更新候选

定点复核记录

• S01 元音标注消融：FT-GAN Table 3 的 Pro/Nat/Exp/Con 列分别为发音、自然度、表现力、音高一致性；w/o Vowel Morphing 行依次为 0.43/ 0.36/ 0.23/ 0.18。因此 0.43是发音比较MOS，不是自然度分数。

• S05 数据时长：TCSinger 附录 B Table 7 的 Total/h 行印为294；但同表各数据集总时长36+30+85+85+18=254，§4.1及附录 B 正文也列这些分项。本卡片删除合计，只保留数据集名称与留出40歌手，避免把有冲突的原文总计作为已核实数值。

• S06 技巧评估与会场：F1 0.770属于 Table 4 的音频技巧检测器，评估六种非滑音技巧；不是歌唱成功率，也不是文字提示预测器指标。AAAI 官方论文页和卷期目录均确认2025年主会技术轨、39(22)、23978-23986，正式发表日期2025-04-11。

小夏 v1.2：歌唱 / 戏曲模型与制作基座选型

核查日期：2026-11-04（北京时间）。范围：一手论文、作者实现、官方模型卡和推理入口的静态核查；本轮未在 RTX 5070 Ti 上运行模型。

结论：专项需要独立，但声音人格不分裂

建议建立"表演与音乐制作"专项，共享小夏的身份、认知状态、会话和播放控制，单独拥有表演条件、渲染任务、分轨与段落修订。

最值得做的不是从零训练一套音频基座，而是拥有自己的表演规格、声音资产、可恢复任务和验收体系，在其后接可替换的成熟渲染器。以下四个候选覆盖三类互不替代的工作：保留已有表演换声、按歌词与谱重新演唱、生成整曲编配。SoulX-Singer 还可覆盖前两类之间的桥接。是否合并成一个模型、是否引入新论文，由交付效果决定。

合同原则：项目交付是不变量；论文、模型、算法、内部表示和部署拓扑均可比较、组合、修改、替换或放弃。 替换提交同条件作品、资源记录、回归结果和理由，不要求为维护某篇论文而维护一个模块。

一、四个候选，各自承担什么

候选	建议承担的交付	小夏应拥有的衔接层	选型位置
SoulX-Singer SVS + SVC	参考唱段换声；歌词和旋律条件的新唱	参考选择、元数据转换、长曲分句和拼接	综合歌声首个比较候选
Seed-VC V1 SVC	参考表演换声的第二条基线	目标调性、固定条件、身份 / 内容对照	验证是否需要更复杂路线
OpenVPI DiffSinger + OpenUtau	按谱新唱；逐字、逐音、逐句修订	作品时间轴、音源、简化编辑界面	精细可编辑路线
ACE-Step 1.5	全曲作曲、伴奏和编配	结构意图、任务适配、分轨回混	完整创作路线

1. SoulX：当前最值得优先试的综合歌声候选

论文把歌词、音符类型、时长、离散音高或连续 F0 对齐到声学时间轴，再由 flow-matching DiT 生成频谱。连续 F0 条件适合保留细致旋律运动；音符条件适合改词与重唱。小夏可借用的是"内容、时间、音高、身份分别提供条件"的机制。[MB01]

工程事实：代码及权重 Apache-2.0；2026-03-16 发布独立 SVC 权重，入口 cli.inference_svc，输入音频和 F0。已有分离、去混响、转词转谱及 MIDI 元数据编辑链；用户友好 MIDI 输入仍列待完善。SVC 界面建议干净歌声参考，并提示宽音域长歌的音色稳定性问题。[MB02-MB05]

因此首轮应比较"单参考 / 按音域选参考 / 分句重做"，分别验收底层合成和谱面导入体验；不把整曲一次生成、单参考或特定元数据格式固定成合同要求。

2. Seed：有价值的对照，不作为唯一长期依赖

论文的核心贡献是训练时扰动源音色、减少源说话人泄漏，并利用整段参考上下文；唱歌额外加入 F0 条件。[MB07]

工程事实：V1 的 44.1kHz F0 条件模型面向歌唱，V2另做口音 / 情绪变换；入口 inference.py --f0-condition True。官方支持Windows / Linux，代码及模型卡GPL-3.0。仓库2025-11-21归档。README的3060 Laptop实时表针对tiny语音换声，并非该SVC模型。[MB08-MB10]

建议保留戏曲表演时默认关闭自动移调，显式选择目标调性；用它做可复现对照，自维护成本一起进入选型，而不是只看试听。小夏已接入的Seed链路继续保留，归档本身不是立即替换触发器；只有同条件作品、兼容性或维护成本对照显示明确收益，才迁移新引擎。

3. DiffSinger：作品可编辑性的基座

作者仓库确认原作发表于AAAI2022。OpenVPI实现使用.ds、variance / acoustic推理与ONNX部署，代码Apache-2.0；音源另查许可。OpenUtau为MIT编辑台，有音高、音量、能量、气声、张力曲线，部分取决于音源；默认CPU，Windows可DirectML。[MB11-MB14]

我的建议是借用这套编辑能力和交换格式，让小夏只暴露必要操作。每次改一个字、一个装饰音、一口气都能限定影响范围。专用小夏音源是独立数据 / 训练决策，不从四秒语音推导出"现成全音域戏曲音源"。

4. ACE-Step：作品创作与编配，不抢认知核心的职责

ACE-Step 的论文将结构规划与声学渲染分开，用 LM 输出作品条件、DiT 渲染波形潜变量，并通过源音频与 mask 统一生成和编辑。小夏可保留自己的高层创作意图，再调用该模型的结构化能力。[MB15]

工程事实：代码和权重MIT；XL4B于2026-04-02发布。turbo / sft有reference、text2music、cover、repaint，extract / lego / complete需要base类变体；2B与XL遵循相同功能划分。现成Windows包要求CUDA12.8，提供Python及异步REST入口。[MB16、MB18-MB20]

"先完整创作，再分离人声、按小夏身份重唱 / 换声、最后回混"是值得测试的组合路线；"直接由音乐模型凭身份参考生成"也是候选。以音色稳定、歌词准确和制作效率决定保留哪条，不要求人为固定两段式。

二、四秒语音参考如何扩展成同一个小夏

原四秒参考保留为声音身份起点。新增素材按能力取得，不要求一次凑成大型语料库：

1. 身份锚点：原四秒、干净中性说话、不同元音 / 音区的可用样本，保存原件、来源、版本和质量评语。模型可以使用不同特征表示，不规定跨模型共用一条 speaker embedding。

2. 歌唱覆盖：短歌声、长元音、低中高音区、真假声转换；先做不同参考选择的对照，再决定是否收集更多或训练轻量适配。

3. 表演参考：某一剧种 / 行当的唱段、咬字、润腔、拖腔、收尾和气口，与身份参考分开管理。参考表演可以来自另一个表演者，模型任务是保留其艺术动作并映射到目标身份。

4. 长期固定版本：用户认可后才把候选声音 / 适配器升级为新的身份版本；失败生成不自动回灌成训练事实。说话、哼唱、流行歌、戏曲一起做跨模式试听，防止各路模型分别长出四个声线。

建议数据对象为 VoiceIdentityProfile 与 PerformanceSpec 两份，而非一份"音色 + 情绪 + 剧种"的混合 prompt。前者回答"谁在发声"，后者回答"这一次怎样表演"。戏中的悲喜也不应直接覆盖小夏长期认知层的情绪状态。

三、制作流水线：复用成熟工具，自己拥有作品和任务

> 对应关系见随附两页《项目架构图 v1.2》。可编辑研究稿保留 Mermaid 源。

成熟组件覆盖：人声分离与去混响、RMVPE 等 F0 提取、已有歌词 / 谱对齐工具、重采样与混音。自己实现的是领域层：

• 表演规格：歌词 / 音素时间段、连续 F0、音符和滑音、气口、音区、剧种 / 行当、参考片段、目标调性、可编辑区间。谱面有量化音符，表演仍保留连续曲线；不能把戏曲润腔强压成十二平均律方块。

• 可恢复渲染任务：输入资产哈希、引擎版本、条件、随机种子、阶段产物和状态。已完成的人声分离 / 分句结果可以复用。暂停 / 停止播放只操作播放器；取消制作才取消生成；打断后是否继续后台制作按该次用户意图处理；不把"某条推理不支持中途恢复"伪装成已经恢复。

• 作品修订：全曲结构与连续时轴是权威；允许只重做一个字 / 一句 / 一个声部，保存原分轨、修改区间和输出。优先在气口 / 乐句边界切段，以重叠上下文与交叉淡化连接，不在拖腔或爆破音中间随意切。

• 统一播放器：边播边聊天、打断、暂停、继续、切回原段落。音乐成品渲染的耗时与实时聊天首包是两个预算，分别验收。

供应方任务API由专门适配器调用；认知核心持有小夏自己的任务与作品标识。

四、5070 Ti 16 GB：资源与环境怎样落地

路线	官方可核条件	小夏机器上的第一道任务
ACE-Step 2B	16GB归Tier6a，推荐1.7B LM；CPU offload与INT8默认启用	2B turbo、batch=1起测；记录冷 / 热启动、峰值、耗时、聊天受影响情况
ACE-Step XL4B	16GB归Tier6a，XL按CPU offload运行；更低12-16GB档需激进offload，20GB以上更适合常驻	与2B并排盲听，收益不足就不用XL；不挤掉实时语音
SoulX-Singer	requirements固定torch / torchaudio2.2.0，含SageAttention、NeMo；无已核完整链16GB预算	先适配Blackwell环境，再分阶段测预处理 + 合成；Windows原生或WSL做实测选择
Seed-VC 44.1k	无已核5070Ti完整链资源表	固定版本单worker，记录参考长度 / 句长 / 采样步数对峰值和RTF的影响
DiffSinger / OpenUtau	见上文部署入口	先用合适音源跑编辑链，再决定专用音源；训练与在线推理分别预算

关键环境证据：PyTorch官方2.7才明确加入Blackwell与CUDA12.8预构建支持。旧固定依赖需先适配；WSL不会自动补上旧轮子缺少的GPU架构支持。[MB21]

本地采用实时语音优先、作品任务排队或分阶段释放模型的资源策略；允许把重型训练或高质量离线渲染接远程worker。交付测量包含整条链和并发聊天，不以某个200M或4B参数量推算整机可用性。64GB系统内存有助offload，但不等于显存或实时速度。

五、供比较的三个能力包

A 包对应完整指定作品的交付；其中局部编辑与分轨编辑是增强候选。B 包的精细词谱编辑、C 包的全曲原创均由 Owner 采纳后进入验收。此处编号不与主合同的 M1-M6 里程碑混用。

候选 A：参考表演→小夏声音的完整作品

SoulX-SVC 与 Seed-SVC 用同一批样本比较，样本包含普通歌曲及至少一种明确剧种；覆盖长拖腔、宽音域、快速字头、假声和伴奏混响。交付完整作品、干声与伴奏分轨、可回放任务记录；若采纳局部编辑，再增加“重做指定一句，其余不变”的操作。原来四秒说话参考与增加歌唱参考进行成对对照，说明增材带来的真实收益。

候选 B：新歌词 / 新谱→可修订演唱

比较 SoulX-SVS、DiffSinger 或新的更合适模型。交付歌词 / 谱输入、发音修订、连续音高与时长控制、局部重渲染、身份保持。戏曲另设剧种 / 行当参考与表达评审，允许只先交付一个唱法的可靠闭环。

候选 C：小夏完整创作与陪伴播放

以 ACE-Step 为首个完整创作候选，给定主题、歌词或动机生成作品；能继续聊天、暂停续播、改变编配与返修段落。固定身份采用“直接条件”或“后置换声 / 重唱”的优胜路线。交付结果可导出、可重做、可恢复，而不是仅调用一次 demo。

共同验收维度：身份相似及跨音域稳定、歌词 / 方言可懂、旋律与节奏、气口 / 润腔保留、接缝及音质、局部修改影响面、完成率、渲染时间 / RTF / 显存峰值、播放打断与恢复、作品及资产可导出。参考重演模式按原表演评估；自由创作模式按用户条件和作品连贯性评估。F0指标在有声段计算，并单列时序误差；戏曲连续滑音不按偏离平均律自动扣分。人工盲听与客观指标同时留档。

首轮对照用来确定门槛，再冻结验收集；后续模型仍可替换。研究路线失效就改研究路线，不改小夏应交付的能力。

一手参考索引

这些是4组模型 / 论文及其部署证据，不把README、配置文件凑成论文数量。

- MB01 SoulX-Singer，2026技术报告，方法2.2、评估3：官方原文 / 资料
- MB02 SoulX官方仓库与发布记录：官方原文 / 资料
- MB03 SoulX预处理与MIDI编辑流程：官方原文 / 资料
- MB04 SoulX SVC推理脚本：官方原文 / 资料
- MB05 SoulX SVC界面实际指导：官方原文 / 资料
- MB06 SoulX依赖固定：官方原文 / 资料
- MB07 Seed-VC，2024预印本，方法3、歌唱3.5：官方原文 / 资料
- MB08 Seed-VC模型 / CLI / 实时表 / 归档状态：官方原文 / 资料
- MB09 Seed-VC代码许可证：官方原文 / 资料
- MB10 Seed-VC官方权重许可：官方原文 / 资料
- MB11 DiffSinger，AAAI 2022，作者正式实现：官方原文 / 资料；论文：官方原文 / 资料
- MB12 OpenVPI DiffSinger维护实现：官方原文 / 资料
- MB13 OpenVPI DS推理与ONNX导出：官方原文 / 资料
- MB14 OpenUtau DiffSinger编辑 / 推理能力：官方原文 / 资料；Windows安装：官方原文 / 资料
- MB15 ACE-Step1.5，2026技术报告，方法3：官方原文 / 资料
- MB16 ACE-Step1.5最新模型变体：官方原文 / 资料
- MB17 ACE-Step官方GPU分档：官方原文 / 资料
- MB18 ACE-Step官方安装：官方原文 / 资料
- MB19 ACE-Step异步API与repaint参数：官方原文 / 资料
- MB20 ACE-Step官方权重：官方原文 / 资料
- MB21 PyTorch2.7 Blackwell/CUDA12.8支持：官方原文 / 资料

统一模型方向与本地语言候选

本节区分模型机制参考与现成部署入口；统一模型可以竞争，也允许专业模型组合继续胜出。

U01 · UniVoice: A Unified Model for Speech and Singing Voice Generation

• 类型：2026 年预印本；原文。

• 已读：§3 条件分解、共享 DiT 与 null melody；§4 基准；§5 主实验和消融；§6 局限。

• 机制：内容、旋律与音色分别提供条件，共享 flow-matching DiT；歌唱输入 MIDI，日常语音用可学习空旋律条件，让语音自己形成韵律。

• 实验：使用 30k 小时语音与 35k 小时歌唱，约 0.3B；测试为 10 秒片段，非整曲。表中去掉条件分解会增大两种任务的音素错误。

• 取舍：原文自然度 / 部分基线数值在正文与 Table 1 间不一致，本文采用可检验机制，不据其排行榜选型；代码与权重的可获得性须单独核验。

• 小夏实验：同一身份参考，比较说话、唱歌、过渡与高低音；量化质量、等待、身份漂移和完整作品效果，再决定是否合并后端。

U02 · Qwen3-Omni Technical Report

• 类型：2025 年技术报告；原文。

• 已读：§2.1 总体、§2.4 Talker、流式推理及实验设置。

• 机制：Thinker / Talker 分工，Talker 的文本条件不再依赖 Thinker 高层文本隐藏状态，同时保留音频 / 视觉条件；该接口便于衔接文本侧检索与工具结果。

• 小夏启发：理解能力与声音生产可以联合训练，又允许外部语义流程介入。可比较原生语音对声学信息和话轮处理的收益，同时接入小夏持久状态。

• 选型边界：报告的流式首包是在其优化环境测量；本项目分别测实际设备、网络与播放时延，演唱 / 戏曲能力另按相应任务验收。

U03 · Qwen3.5-9B：本地语言 / 视觉候选例子

• 类型：官方开放权重与模型卡，不计为新增会议论文；官方模型卡。

• 已读：模型规格、推理部署、上下文与 thinking 配置、量化入口。

• 用途建议：离线 / 低成本模式的可运行候选，不替代对强推理质量的要求。16 GB 机器先做可用量化与有限上下文试验，记录实际内存、首响应、长对话质量及语音并行效果。

• 不把标称超长上下文全开当作默认部署；也不依据参数量判定整套模型能够同时常驻。主模型选型仍由同一组小夏任务比较决定。

从统一到专业，保持一份有效身份与状态

项目可以采用统一音频模型、共享音色表示、多专业模型或其中的组合。关键接口是作品、意图、经历与真实交付；每个模型内部特征、采样与私有状态由适配层负责。失败时保留完整输入、输出和版本，替换后用同一作品与交流旅程回归。

小夏基座专项：自有薄内核，复用成熟通道与媒体运行时

研究日期：2026-11-04（北京时间）核对仓库：xxu29958-jpg/xiaoxia，main@8c63aff5a18fcccd624ad0f29ee70f303e15975b。 范围：应用/runtime 架构方向与工程合同补充；只读研究，未在用户机器执行验证，未修改仓库。以下“当前”来自静态代码或仓库记录，“建议”是可替换设计。

1. 明确结论

基座不要整体从零写。要自己掌握的是“小夏是谁、经历了什么、正在做什么、实际交付了什么”的薄领域内核；聊天通道、实时媒体、模型推理和编解码复用成熟组件。

当前推荐组合：

• 渠道层：暂留 AstrBot 的 QQ / 微信适配与管理入口；把它当可替换渠道壳，不让其内部会话、插件对象成为“小夏”的唯一身份。

• 领域内核：Python 普通模块 + 明确的数据与状态转换；初期与现有进程同部署即可。只抽出已经发生的跨通道、跨模型、跨重启共享规则，不先造通用 agent 平台。

• 持久状态：单机先复用现有 Python / SQLAlchemy 能力，采用 SQLite + 明确事务；记忆内容、作品、任务、投递各自有主键和版本。音频文件在文件系统，数据库存 manifest、摘要、阶段和引用。

• 实时语音：桌宠 / 网页真流式交谈，优先用 LiveKit Agents 做一个完整候选切片；Pipecat + SmallWebRTC 是单用户、本机优先的轻量备选。先选一种跑同一组体验用例，不把两套 agent 运行时层层叠加。

• 唱歌 / 戏曲：独立模型工作进程 + 可恢复的作品任务；与实时播放和认知内核分开调度，不能靠拉长一次 HTTP 请求维持整个作品生命周期。

• LangGraph：复杂认知编排出现实际维护收益时再引入；它的执行图不是记忆联想图。

• Temporal：跨机器、跨天、多外部步骤的恢复与调度已成为实质运维负担时再引入。现阶段不为单机一张 GPU 提前配一套分布式工作流服务。

这些均是默认方案，不是冻结选型。交付与验收是约束，框架、模型、论文路线可组合、替换或删除。

语言模型基座与运行基座分开决定

建议默认采用可替换的强云端模型承担语言理解、长程规划与复杂推理，本地语音 / 演唱工作进程承担声音生产。无需为“有自己的认知网络”从零预训练一个语言大模型，也不必把主推理能力先压缩到 16 GB 显卡的单卡容量。认知长期更新可以先发生在自有经验、关联、工作状态和策略中；是否训练 adapter / 小模型，由明确数据与实验收益决定。

公开仓库中的可核事实：[R12]

• Ada companion 的公开 _conf_schema.json 把 provider_id 默认设为 chatgpt-companion；这是 provider 别名，不是具体模型型号。

• AstrBot 公开 default.py 的 provider_sources 与 provider 初值均为空数组；xiaoxia.py initialize() 预配本地 ASR，未固定主聊天模型。

• Codex OAuth 插件公开 schema 的模型列表以 gpt-5.6-sol 开头，并列 gpt-6.1-sol、gpt-6-astra、gpt-6-sol、gpt-6-luna 等；README 要求用户另行添加并选为会话 / 默认提供商。这是候选配置，不能据此认定运行机当前实际使用首项或全部可访问。

具体选型交给同一组小夏任务对照：复杂上下文连续性、中文日常对话、工具可靠性、首响应与费用；强云端候选选综合表现更好的一个主用，另留一个已验收替代即可。本地小模型是离线、隐私或成本模式的独立候选，不自动成为全项目默认天花板。模型选择和推理深度允许按任务调整，但“小夏是谁”和已经发生的事情不随服务商改变。

2. 仓库给出的真实起点

已读证据	当前静态事实	对方案的意义
pyproject.toml	项目仍标为 AstrBot 4.29.1，Python >=3.12，已有异步 SQLite、SQLAlchemy、QQ / 微信相关依赖	不需要再引入一套数据库 / HTTP / 调度基础设施来证明架构升级
ada_companion/main.py	AdaCompanion(Star) 集中装配 owner memory、dialogue、replyer、voice、browser、desktop、initiative 等服务	自有领域规则可以从装配边界渐进抽出；无需整体重写所有功能
shared_core.py、services.py	已有跨关联会话共享 core memory、revision 校验；memory 服务通过已激活插件定位	不是“没有内核、没有持久化”；下一步是明确权威与可替换接口，保留有效代码
policy.py	主动投递已有独立持久策略，先预留后网络发送；JSON 临时文件、flush/fsync 后替换	可以复用既有投递语义，不必推倒重写；多状态一致更新需要事务时再收敛到数据库
lifecycle.py	跟踪进程内任务，插件卸载等待后取消	解决热重载中的操作收尾；整曲任务的重启续做仍需要持久任务与工件状态
services/runtime.py、setup.ps1、xiaoxia.py	Windows 路径、PowerShell 安装、多个 Python 环境和独立语音服务已经存在	GPU 服务独立依赖环境是现有现实，不宜强迫所有依赖塞进 bot 同一个环境
local_voice.py、server_singing.py	/cover 同步等待完整作品，调用总超时为 3600 秒；工作端返回最终 WAV 并存结果记录	新交付合同首先应补任务 ID、阶段状态、取消 / 恢复与取件，不是先换 orchestration 框架
response_media.py	语音成功状态是 attached_to_reply；这是回复中挂上附件	需要保留“生成、挂载、通道接受、真实播放”不同层级，不能统称已让用户听到
docs/voice-api.md	仓库记录 Fish S2 + Seed-VC 候选在 16 GB 显卡上让说话与演唱依次使用 GPU；长曲期间语音回复等待、文字仍可继续	当前最明确的资源压力是长曲与说话的抢占 / 让出 / 远端备选，不是节点数量不够

GOAL.md 的当前记录是“候选已切换，按用户要求暂停继续施工，完整目标未完成”。QQ 原四秒声线、QQ / 微信、未来桌宠复用、完整歌曲和戏曲目标仍在。这里补研究与可执行合同，不改变暂停记录。[R1-R11]

3. 最容易混淆的六类状态

状态	保存什么	谁拥有权威	典型寿命
小夏连续认知	经历、关系、当前关切、偏好、记忆激活 / 巩固 / 有意遗忘	小夏领域内核	跨会话、跨重启
业务工作与交付	用户意图、任务、取消意图、作品、投递结果、待核对结果	领域任务 / 交付记录	到闭环及必要留存完成
编排执行	跑到哪个节点、重试次数、checkpoint	所选 workflow runtime	某次执行 / 恢复窗口
模型上下文	本轮使用的消息、摘要、工具结果、选中记忆	内核生成的派生视图；模型 SDK 管传输	本轮或短会话
媒体实时状态	采集 / 播放时钟、音频帧、队列、speech/turn epoch、已播放范围	实时媒体运行时与客户端反馈	毫秒到通话时长
作品生产状态	音源 / 曲谱、分离结果、分段演唱、声线版本、混音、成品	作品任务和工件 manifest	分钟到数天

由此产生三个明确规则：

1. graph state、模型 messages 或 LiveKit/Pipecat session 都不能单独充当整个“小夏”的数据库。

2. 遗忘是认知机制：可以衰减、压缩、降低可提取性或按用户意愿删除。重启把未完成作品和关系状态弄丢，是运行缺陷，不是有意义的遗忘。

3. “生成成功”只推进到工件可用；“通道接受”只推进到发送结果；只有可获取的客户端播放证据才写入播放范围。QQ / 微信没有收听回执时保留为未知，不补造“听完”。

LangGraph 官方文档本身也区分 thread checkpoint 与跨 thread store；故可以采用它的实现，但小夏对记录意义的定义必须保持清楚。[F1]

4. 该自己写、该复用什么

部分	默认处理	小夏自己负责的最小内容
身份与连续状态	自有领域代码，复用现有可用模块	人 / 会话映射、记忆更新语义、任务与作品归属、用户控制、迁移
认知与回复选择	自有策略 + LLM；不先写大而全规则引擎	当前体验与目标如何进入上下文；计划和执行结果如何回写；可测的激活、反馈、巩固机制
QQ / 微信	复用 AstrBot 适配器及现有实际通道	输入去重标识、能力声明、消息 / 附件转换、结果映射
模型	复用官方模型 / 服务 / 推理运行时	少量模型适配；特性、版本、资源需求与实际结果记录
实时媒体	LiveKit Agents 或 Pipecat 候选	接入共享内核、说话与歌唱模式、暂停 / 取消语义、播放进度回写
演唱生产	复用成熟分离 / SVS / SVC / 音频处理；小夏自有作品工作流	曲目输入、音色 / 表演配置、阶段 manifest、完整性、失败恢复、交付
数据库 / 事务 / 备份	复用 SQLite / SQLAlchemy 等成熟实现	schema、迁移、事务边界、备份包清单与恢复验证
编解码、WebRTC、VAD、ASR、声码器、GPU 内核	复用	只在明确测得缺口时改适配器或贡献上游修复

“薄”是职责少，不是容错少：一次写入意图并建任务、一次提交完成工件并安排投递，分别形成清楚的事务边界即可。也不是必须拆多个 HTTP 服务；只有 GPU 依赖隔离、进程崩溃隔离、不同设备部署等实际压力才拆进程。

5. 编排基座对比与切换条件

方案	真正解决的事	选它的条件	小夏当前建议
Python + SQLite + 显式状态机	本机任务受理、有限阶段、事务、可观察的恢复 / 取消	主要一个用户、一台主机，长任务阶段可枚举	默认；最少部署件，复用现有依赖
LangGraph	分支 / 循环认知流程、线程检查点、人工介入、可检查执行轨迹	多轮计划、反思、工具分支已难以用普通函数维护；同一切片有可度量收益	可作认知编排库；不强制所有聊天经过图，也不把音频帧塞进图
Temporal	服务端持久 workflow、跨 worker 调度、长时间等待与恢复	任务跨机器 / 远端队列 / 人工审批，运维确实需要统一耐久执行历史	后续替代任务执行器；不是当前必装服务

LangGraph checkpoint 有不同持久策略，选择异步或退出时写入会改变崩溃可恢复范围；对需要“受理后必有记录”的业务，必须明确定义受理边界。[F2] 无论换成 LangGraph 还是 Temporal，外部发送丢失回执都要进入未知 / 核对状态；runtime 本身无法知道收件端是否已经接受。Temporal 官方明确要求活动幂等。[F3-F4]

SQLite WAL 适合本机多读单写压力，不能把活动数据库直接放到网盘 / 跨机共享路径当远端数据库；备份用在线备份接口或经验证的静止备份，再同步备份件。[F5-F6] 若真正形成多个独立远端写入节点、单写者成为瓶颈，再考虑 PostgreSQL。数据库升级也不自动触发 Temporal。

不按“超过 X 个节点就换框架”决定。用同一业务切片比较：新增依赖和运维成本、失败恢复正确性、调试时间、延迟 / 资源、后续修改范围。收益不足则不引入。

6. 实时媒体基座与 Windows / 渠道适配

优先候选 LiveKit Agents，备选 Pipecat；先做 1 个可替换的真实交谈切片。

项目	LiveKit Agents	Pipecat + SmallWebRTC
默认侧重点	房间 / 实时媒体 + agent session；桌面、网页、移动端链路较完整	可组合音频处理管线；P2P 适合本机 / 少量终端快速验证
部署形态	LiveKit Cloud 或自托管媒体服务 + agent；不要把 Cloud 误当唯一选项	SmallWebRTC 无第三方媒体服务账号也能工作；跨网仍需验证实际 NAT / 中继策略
打断	有 turn detection、interrupt 与按播放截断上下文机制	InterruptionFrame 清理生成 / 队列；下游按实际输出文本提交上下文
小夏要适配	本地 ASR / TTS/S2S、共享 cognition、作品播放和返回聊天	同左；框架消息不能取代小夏领域记录
优先用它的理由	若目标包括跨设备实时房间 / 未来移动与网页，优先减少媒体基础设施自研	若近期就是单机桌宠，且本机媒体 / 自定义模型链路更顺，可反转为主方案
切换判据	本机目标版本安装成功；插话、连续 30 分钟交谈、音频设备变化、网络恢复、唱后回聊通过	相同；并比较实际延迟、CPU/RAM、依赖体积和调试成本

LiveKit 官方有 Windows CLI 与本机 server 安装入口；Python Agents 要求 Python >=3.10。Pipecat 当前 quickstart 要求 Python >=3.11，官方 C++ client 明确支持 Windows，server transports 提供 SmallWebRTC / WebSocket / Local 等选择。[F7-F11] 这说明存在 Windows 实施路线；不把一个 CLI 或 client 的支持声明扩展为“每个 Python extra / 模型 wheel 均已在本机验收”。为两个候选各建独立测试环境，直接验证选中的 transport、模型插件与录放设备；不先迁到 WSL。

关键渠道事实：

• QQ / 微信语音消息是录制完后作为消息或文件传递，与 LiveKit/Pipecat 的实时通话不同。媒体 SDK 接入不能自动获得 QQ / 微信的麦克风直播或通话控制能力。

• AstrBot 官方支持 Windows 部署、QQ 官方与 OneBot v11；OneBot 文档也列有 NapCat Windows 部署入口。[F12-F13]

• 当前 AstrBot 的个人微信 weixin_oc 文档写明语音输入可被云端转录、语音发送不支持、文件发送支持；公众号 / 企业微信是不同通道。[F14] 本仓库还有 wechat-companion 目标和本地网络适配，不能未经核对就替换为 weixin_oc，或用官方适配器能力宣称现有个人微信链已验收。

• 保持用户当前已选体验：QQ 普通语音可直接播放；微信可以附件播放。完整长作品的大小 / 时长限制按实际通道处理：合适编码、文件或可访问作品链接，不截成“只有几句”冒充完整交付。

7. 推荐拓扑：模块边界，不是微服务要求

> 对应关系见随附两页《项目架构图 v1.2》。可编辑研究稿保留 Mermaid 源。

普通聊天以低延迟路径完成；整曲生成走持久任务。实时播放时钟留在媒体层，内核只收有意义的事件，如“说到哪个句段”“用户已打断”“作品播放结束 / 未知”。无需逐音频帧写数据库，也无需每个 20 ms 帧调用一次 LLM。

8. 演唱、语音与 16 GB GPU 的具体约定

当前串行 GPU 路径需要显式产品决策：正在准备一首长曲时，用户继续聊天，应能立即得到准确的状态反馈；是否继续语音、暂停生成、使用独立 / 远端语音候选，由已选择运行模式决定，不静默挂起。

建议只做必要调度：

1. 生成任务和播放任务分开。停止播放不等于删除作品 / 终止生成；取消制作才停止生成；“继续唱”明确恢复哪个对象。

2. 请求入库即给任务 ID，不维持 3600 秒连接作为唯一生命线。客户端可重连查询同一任务与成品。

3. 工件按阶段提交：输入准备 → 人声 / 曲谱准备 → 分段生成 / 转换 → 混音 → 完整性检查 → 可交付。已完成阶段用版本与文件摘要校验后复用。

4. 让出点在可验证的音频片段边界，不是假设能随时抢占正在运行的 CUDA kernel。若短语音延迟预算无法靠让出满足，则测试更小常驻语音模型、云语音或分离计算；哪条达到交付指标就选哪条。

5. 交谈和唱腔不同声学策略。演唱应保留长音、音高运动、板式与伴奏；不要无条件经过为语音电话优化的降噪 / 自动增益 / 端点检测。客户端音乐模式、增益、立体声与输出采样率均用实听与波形验证。

最小数据设计可从现有模型演进：task_id、owner_id、intent_id、stage、attempt、cancel_requested、model/reference/version、artifact_manifest、delivery_status。这些是此轮可用的合同草案字段，允许 Codex合并精简；不得为了字段齐全创建永远不使用的抽象层。

9. 渐进替换路线

第一片：让一个完整作品可恢复交付。 复用现有音源 / 模型接口；增加持久任务、阶段工件和取件，验证杀进程 / 重启 / 重复请求。现有短语音和 QQ / 微信不重构。

第二片：让同一小夏跨渠道连续。 提取 owner、经验 / 工作状态和回复计划接口；AstrBot 的事件转成小夏普通输入数据。先迁一个路径，做单写权威切换，旧实现作为只读对照；不长期双写两份独立人格 / 记忆。

第三片：增加真流式桌宠 / 网页语音。 LiveKit 与 Pipecat 候选在隔离原型中跑相同脚本和音频设备；保留达标且维护成本更低者。媒体适配只调用既有内核，不另起一个同名但不共享经历的 agent。

第四片：按压力升级。 复杂认知工作图引入 LangGraph；跨机任务调度再考虑 Temporal；数据库按并发和部署需求升级。每一步只替换自身职责，不连带重写声线、记忆、通道和所有模型。

新内核不要求大规模迁移后才能有收益；现有 shared_core、独立 DeliveryPolicy 和本地 voice API 都能成为第一批复用边界。

10. 可直接并入项目合同的验收条款

以下是建议的验收样例，数值预算在测试前按目标设备定稿，不冒充已达成成绩。

编号	实际场景	完成条件
B1	QQ提出完整演唱任务，处理途中重启 bot	同一个任务可查询；已校验工件不重做；最终成品仍完整，归属不变
B2	歌曲生成中工作进程退出	恢复到明确阶段；未完成段重新生成；不能把部分 WAV 标为整曲
B3	成品发送后、收到通道回执前断网	状态为待核对；有查询能力时查询，无查询能力时提供明确重发选择；不盲目自动重发造成重复轰炸
B4	小夏正在讲话，用户说“停，我不是那个意思”	实际扬声器停止旧音频；迟到结果不能续播；下一轮上下文只记已播放片段及新意图
B5	用户只说“嗯”、短咳嗽或背景有人说话	区分接话、噪声和真实插话；保存原始事件用于比较候选策略，不靠每次全文重新推理

编号	实际场景	完成条件
B6	完整长曲生成同时连续聊天	文字聊天不被 GPU 工作阻塞；语音响应符合已定资源策略 / 预算；进度和等待原因真实
B7	一首戏曲播放中暂停，之后“继续”	从可定位播放点继续；作品不用重做；伴奏、人声时钟同步
B8	同一人在 QQ 聊后改为桌宠语音	采用同一身份、已确认偏好、未完事项；渠道历史没有冒充额外独立经历
B9	替换 LLM或实时框架	任务、作品、记忆、归属和可用控制保留；通过同一用户旅程，不要求两个随机模型逐字相同
B10	一台干净 Windows 机器安装、重启、备份恢复	所选真实模型与 transport 能启动；引用资产一致；恢复后可继续普通语音与完整作品旅程

Codex 自由度条款：

> 本文引用论文、官方实现及候选框架作为理论与工程参考。Codex 可以提出更简洁、更高质量或更适配资源的替代方案，并通过同一交付验收决定采用。修改方案必须记录改变了哪个假设、为何改变及对比证据；不得通过删除完整作品、跨渠道连续性、自然交谈、可恢复交付等用户目标来制造达标。架构图是当前推荐边界，可随实证重绘。

一手来源与仓库定位

仓库证据（固定 HEAD）

- R1 GOAL：官方原文 / 资料
- R2 依赖：官方原文 / 资料
- R3 装配入口：官方原文 / 资料
- R4 共享 core：官方原文 / 资料
- R5 投递策略：官方原文 / 资料
- R6 热重载生命周期：官方原文 / 资料
- R7 语音客户端：官方原文 / 资料
- R8 演唱服务：官方原文 / 资料
- R9 附件状态：官方原文 / 资料
- R10 语音接口 / 测试记录：官方原文 / 资料
- R11 Windows安装与服务配置：官方原文 / 资料；官方原文 / 资料
- R12 公开模型配置（未读取用户凭据）：官方原文 / 资料；官方原文 / 资料；官方原文 / 资料；官方原文 / 资料

官方框架 / 数据库来源（2026-11-04 核对）

- F1 LangGraph persistence：官方原文 / 资料。
- F2 LangGraph checkpointers / durability：官方原文 / 资料。
- F3 LangGraph retry / unknown outcomes：官方原文 / 资料。
- F4 Temporal Activity Definition / idempotency：官方原文 / 资料。本机 Windows CLI：官方原文 / 资料；development server 示例默认用内存数据库，不能直接作为重启恢复交付配置。
- F5 SQLite WAL：官方原文 / 资料。

- F6 SQLite Online Backup：官方原文 / 资料。
- F7 LiveKit voice AI quickstart：官方原文 / 资料。
- F8 LiveKit interruptions：官方原文 / 资料。
- F9 LiveKit local server：官方原文 / 资料。
- F10 Pipecat transports：官方原文 / 资料；quickstart：官方原文 / 资料；Windows C++ client：官方原文 / 资料。
- F11 Pipecat interruption：官方原文 / 资料。
- F12 AstrBot Windows：官方原文 / 资料。
- F13 AstrBot OneBot / QQ：官方原文 / 资料。
- F14 AstrBot personal WeChat：官方原文 / 资料。微信公众号另见 官方原文 / 资料。

使用注记：以上是官方技术文档 / 源码，不把它们包装成顶会论文。认知、实时对话、歌唱与戏曲的研究论文由本次研究包的相应专项提供；运行基座的工程采用仍以目标设备和实际旅程验收决定。